2. Likelihood, Maximum Likelihood und Fisher-Information

2.1 Likelihood

Wahrscheinlichkeitstheorie

- vollständig spezifiziertes stochastisches Modell
- Wahrscheinlichkeiten für interessierende zufällige Ereignisse sollen berechnet werden
- Formal: Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, P)$

Beispiel: Binomialverteilung $Y \sim Bin(n, \theta)$

$$P(Y = k) = P_{n,\theta}(Y = k) = \binom{n}{k} \theta^k (1-\theta)^{n-k} \quad , \; k = 0, \dots, n$$

Bei bekannten Parametern ($n = 10, \theta = \frac{1}{3}, k = 0$) lassen sich Wahrscheinlichkeiten exakt berechnen:

$$P_{10,\frac{1}{3}}(Y = 0) = \binom{10}{0} \left(\frac{1}{3}\right)^0 \left(1 - \frac{1}{3}\right)^{10-0} = \left(\frac{2}{3}\right)^1 0 = 0.01734153$$

Statistik

- auch stochastische Modelle
- aber nicht vollständig spezifiziert, sondern Wahrscheinlichkeitsmaß P hängt von unbekannte(n) Parameter(n) ab
- Parametrisierte Verteilungsfamilie: $\{P_\theta : \theta \in \Theta\}$
- aus beobachteten Daten wollen wir etwas über den unbekannten Parameter θ lernen

Beispiel:

- 10 unabhängige, identische Versuche

- Binomialverteilung $Bin(10, \theta)$ ist geeignetes stochastisches Modell

- Parameter $\theta \in [0, 1]$ unbekannt

- Welche Information über den unbekannten Parameter θ bekommen wir, wenn wir in unserer Serie von 10 Versuchen 8 Erfolge beobachten?

- sicher wissen wir nur, dass $\theta > 0$ und $\theta < 1$

- plausibel ist, dass θ nicht sehr klein ist, denn dann wäre die Wahrscheinlichkeit $P_{10,\theta}(Y = 8)$ sehr klein

- Zu jedem möglichen Wert von θ können wir die Wahrscheinlichkeit, dass genau 8 Erfolge beobachtet werden, berechnen

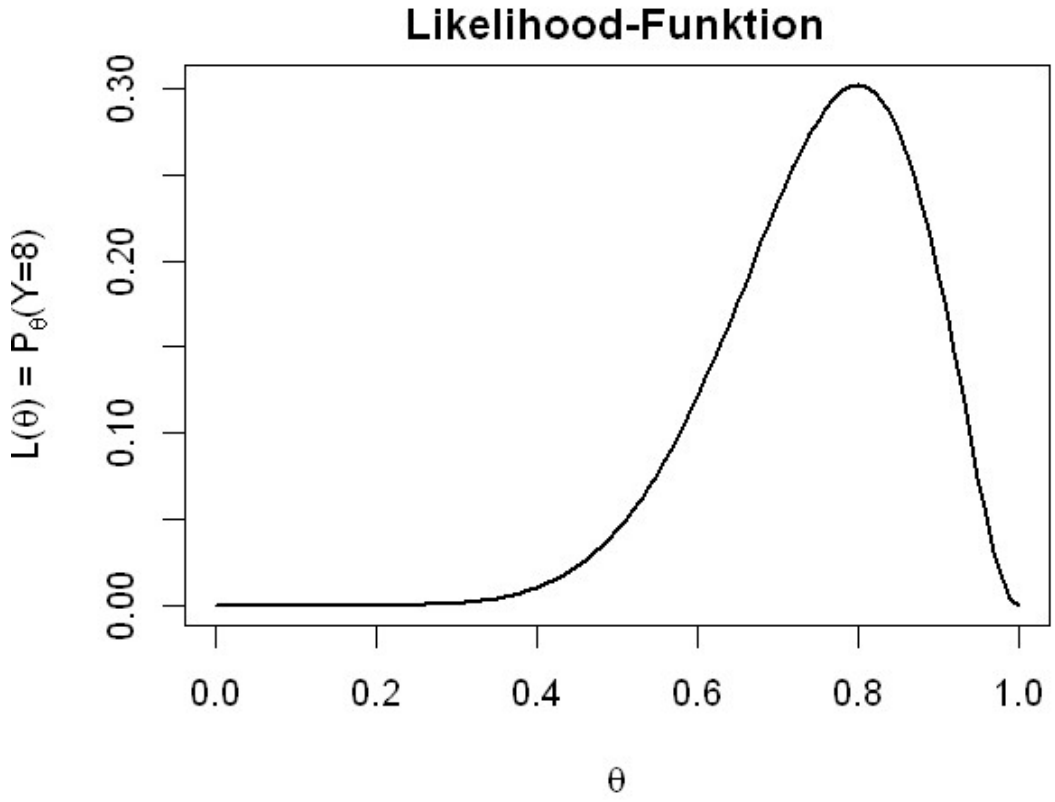
$$\begin{aligned} \theta = 0.6: \qquad P(Y = 8) &= P_{10,0.6}(Y = 8) = 0.1209324 \\ \theta = 0.7: \qquad P(Y = 8) &= P_{10,0.7}(Y = 8) = 0.2334744 \end{aligned}$$

- das erlaubt eine vergleichende quantitative Bewertung der Plausibilität unterschiedlicher möglicher Werte für θ

- Betrachtung der Wkt. $P(Y = 8) = P_{10,\theta}(Y = 8) = P_\theta(Y = 8) = \binom{10}{8}\theta^8(1 - \theta)^2 = \mathcal{L}(\theta)$ als Funktion des unbekannten Parameters

$$\longrightarrow \qquad \textbf{Likelihood-Funktion } \mathcal{L}(\theta)$$

- es erscheint plausibel, als Schätzwert für den unbekannten Parameter denjenigen Wert zu wählen, für den beobachteten 8 Erfolge *most likely* sind



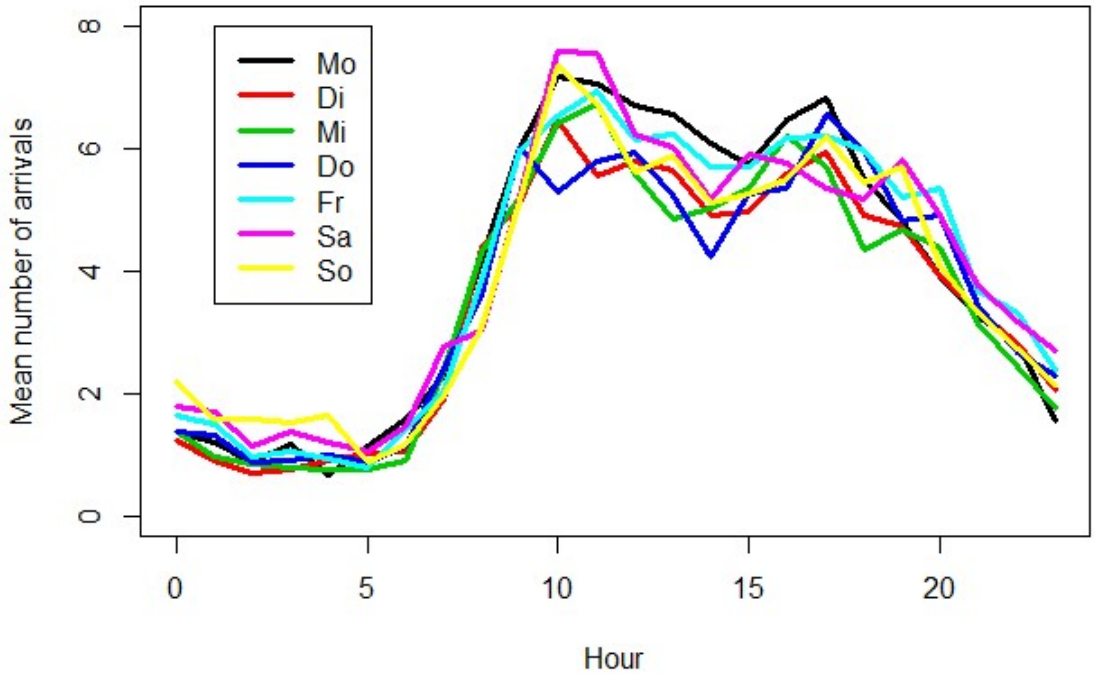
Typische Situation

- $y_1, y_2, \ldots, y_n$ Beobachtungen $\longrightarrow$ *Stichprobe* vom Umfang n
- interpretiert als Realisierungen von stochastisch unabhängigen Zufallsgrößen $Y_1, Y_2, \ldots, Y_n$
- Verteilung der Y_i ist im Prinzip bekannt - bis auf unbekannten Parameter θ

$$Y_i \sim P_\theta, \qquad \theta \in \Theta, \qquad \text{stoch. unabhängig}$$

$$\longrightarrow \text{statistisches Modell}$$

Beispiel: Anzahl ankommender Patienten in Notaufnahme



Beispiel: Anzahl ankommender Patienten in Notaufnahme

- statistisches Modell soll durch unabhängige, identisch verteilte Zufallsgrößen gekennzeichnet sein

- Modellierung getrennt nach Wochentagen und Stunde der Ankunft

$$y_i = \text{Anzahl der ankommenden Patienten am Sonnabend zwischen 8 und 9 Uhr in Woche } i, \quad i = 1, \dots 52$$

3	6	7	7	8	5	8	1	6	7	5	6	2	3	5	4	5	3	5	5	8	11	6	4	7	7	6	4	1
9	9	3	3	5	6	3	2	8	2	9	2	5	6	7	5	2	3	7	4	6	6	4						

Beispiel: Anzahl ankommender Patienten in Notaufnahme

- Y_i - Zufallsgröße, die die zufällige Anzahl ankommender Patienten am Sonnabend zwischen 8 und 9 Uhr in Woche i beschreibt

- Unabhängigkeit?

- Welche Verteilung?

$$Y_i \sim Poisson(\theta) \quad , i = 1, \dots, n, \qquad \theta \in \Theta = (0, \infty)$$

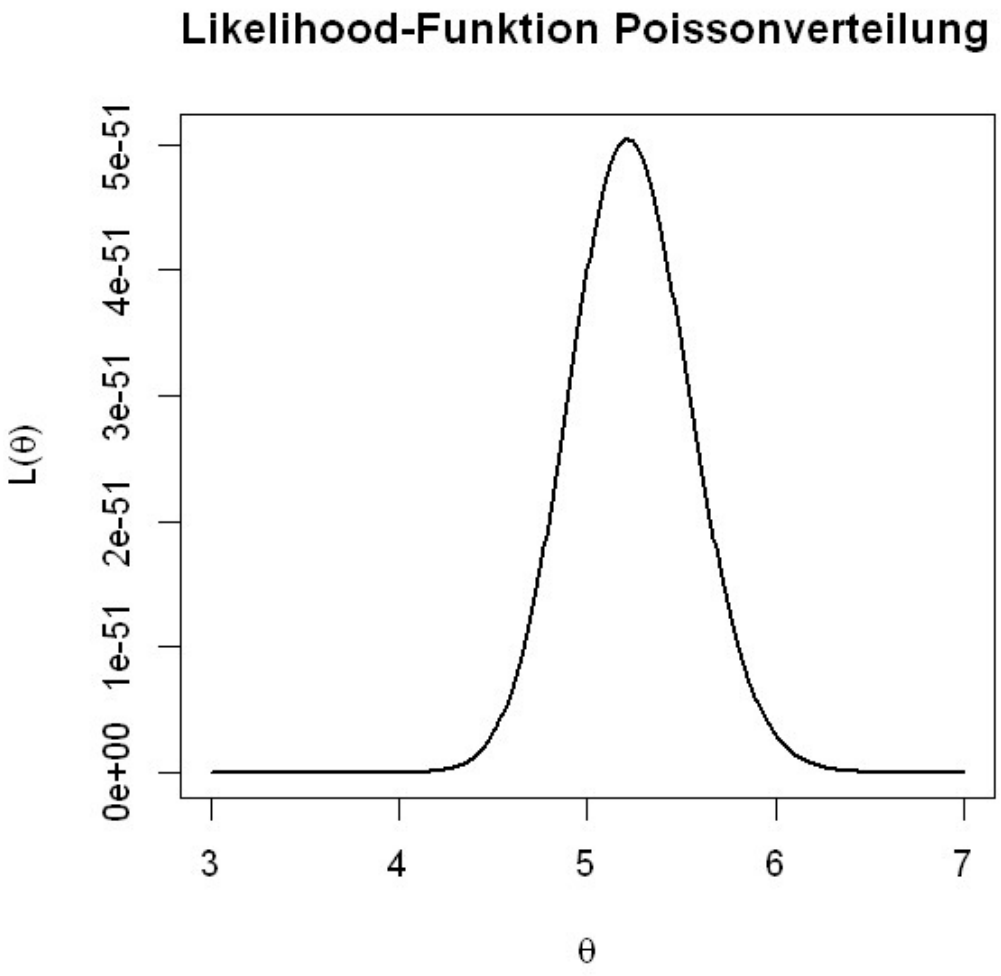
stochastisch unabhängig

- Für jede Woche i gilt dann:

$$P(Y_i = k) = P_\theta(Y_i = k) = \frac{\theta^k}{k!} e^{-\theta} \qquad k = 0, 1, \dots$$

- Wahrscheinlichkeit für konkrete Beobachtungen $y_1, \dots, y_{52}$:

$$\begin{aligned} P_\theta((y_1, \dots, y_n)) &= P_\theta(Y_1 = y_1, Y_2 = y_2, \dots, Y_n = y_n) \\ &\underbrace{=}_{\text{Unabh.}} P_\theta(Y_1 = y_1) P_\theta(Y_2 = y_2) \dots P_\theta(Y_n = y_n) \\ &= \frac{\theta^{y_1}}{y_1!} e^{-\theta} \frac{\theta^{y_2}}{y_2!} e^{-\theta} \dots \frac{\theta^{y_n}}{y_n!} e^{-\theta} \\ &= \frac{\theta^{y_1 + \dots + y_n}}{y_1! \dots y_n!} e^{-n\theta} =: \mathcal{L}(\theta) \end{aligned}$$



Definition 2.1: Es sei

$$Y_i \sim P_\theta \qquad , \theta \in \Theta \qquad , Y_i \text{ stoch. unabhängig}$$

ein parametrisiertes stochastisches Modell und

$$y_1, \ldots, y_n$$

seien konkrete Beobachtungen/Realisierungen. Die ***Likelihood-Funktion***

$$\mathcal{L}(\theta) = \mathcal{L}(\theta; y_1, \ldots, y_n) = P_\theta((y_1, \ldots, y_n)) = \prod_{i=1}^{n} P_\theta(y_i)$$

beschreibt die Wahrscheinlichkeit der Gesamtheit der Beobachtungen $y_1, \ldots, y_n$ als Funktion des unbekannten Parameters.

Bemerkungen:

- $\mathcal{L}(\theta)$ ist keine Wahrscheinlichkeitsdichte
- insbesondere ist $\mathcal{L}(\theta)$ *nicht* die Wahrscheinlichkeit von θ
- für konkrete beobachtete Daten gestattet die Likelihood-Funktion eine *relative* Bewertung der Plausibilität unterschiedlicher Parameterwerte.

Beispiel: Binomialverteilung $\mathcal{L}(\theta) = \binom{10}{8}\theta^8(1-\theta)^2$

- Integration über alle möglichen Parameterwerte:

$$\begin{aligned}
\int_0^1 \mathcal{L}(\theta) d\theta &= \int_0^1 \binom{10}{8}\theta^8(1-\theta)^2 d\theta \\
&= 45 \int_0^1 \theta^8(1 - 2\theta + \theta^2) d\theta \\
&= 45 \int_0^1 \theta^8 - 2\theta^9 + \theta^{10} d\theta \\
&= 45 \left[\frac{1}{9}\theta^9 - \frac{2}{10}\theta^{10} + \frac{1}{11}\theta^{11}\Big|_0^1\right] \\
&= 45 \left[\frac{1}{9} - \frac{2}{10} + \frac{1}{11}\right] = \frac{1}{11}
\end{aligned}$$

Bemerkung:

- Für kontinuierliche Verteilungen mit Wahrscheinlichkeitsdichte $f_\theta(.)$ ist die Wahrscheinlichkeit für konkrete Beobachtungen für alle θ gleich 0.
- Die Interpretation bleibt näherungsweise gültig, wenn wir Wahrscheinlichkeiten für kleine Intervalle $(y_i - \varepsilon/2, y_i + \varepsilon/2)$ betrachten.

- (n=1):

$$\begin{aligned}\mathcal{L}(\theta) &= P_\theta\left(Y_1 \in \left(y_1 - \frac{\varepsilon}{2}, y_1 + \frac{\varepsilon}{2}\right)\right) \\ &= \int_{y_1-\varepsilon/2}^{y_1+\varepsilon/2} f_\theta(y)dy \\ &\approx \varepsilon f_\theta(y_1)\end{aligned}$$

- Vorfaktor ε ist irrelevant für Bewertung der relativen Plausibilität möglicher θ-Werte.

- Für stetige Zufallsgrößen definieren wir die Likelihoodfunktion unabhängiger Beobachtungen als Produkt der Dichtefunktionen:

$$\mathcal{L}(\theta) = \mathcal{L}(\theta; y_1, \ldots, y_n) = \prod_{i=1}^{n} f_\theta(y_i)$$

2.2 Maximum-Likelihood

- Die relative Bewertung der Plausibilität unterschiedlicher möglicher Werte für θ führt auf die naheliegende Idee, als Schätzwert für den unbekannten Parameterwert auf der Grundlage konkreter beobachteter Daten denjenigen Wert zu wählen, der die Likelihood-Funktion maximiert.

Definition 2.2: (Maximum-Likelihood-Schätzung)

Der Wert $\hat{\theta} = \hat{\theta}(y_1, \ldots, y_n)$ heißt ***Maximum-Likelihood-Schätzung*** für den unbekannten Parameterwert θ, falls gilt:

$$\mathcal{L}(\hat{\theta}) = \sup_{\theta \in \Theta} \mathcal{L}(\theta; y_1, \ldots, y_n) \ .$$

Bestimmung der Maximum-Likelihood-Schätzung

- analytische Bestimmung des Maximums einer Funktion

- Hoffnung: Ableiten, Nullsetzen, Maximum gefunden

- *ABER*:
  - lokales Maximum oder Minimum?
  - Maximum im Innern des zulässigen Parameterbereiches?

Bestimmung der Maximum-Likelihood-Schätzung

- direktes Ableiten braucht Produktregel, Vereinfachung durch logarithmische Transformation

Definition 2.3 (Loglikelihood-Funktion)

Die Funktion

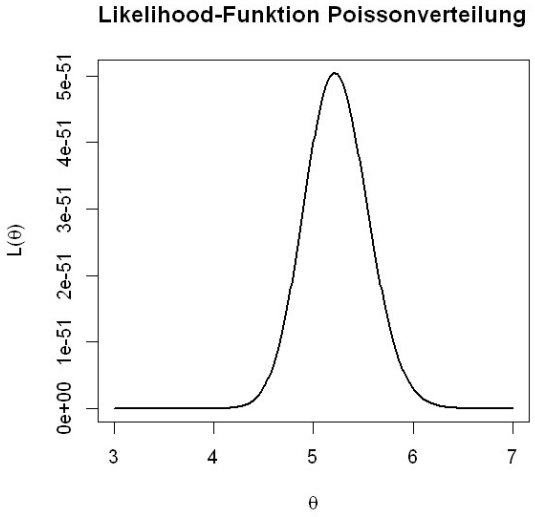
$$\ell(\theta) = \ell(\theta; y_1, \ldots, y_n) = \log \mathcal{L}(\theta; y_1, \ldots, y_n) = \sum_{i=1} \log P_\theta(y_i)$$

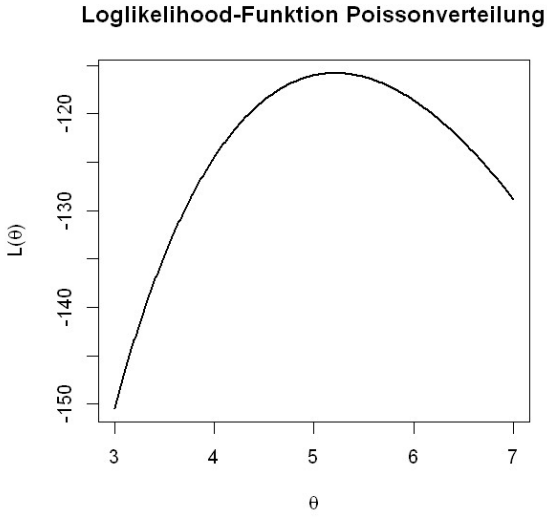
heißt ***Loglikelihood-Funktion***.

Beispiel: Poisson-Verteilung

$$\ell(\theta) = \ell(\theta; y_1, \ldots, y_n) = \log\left(\frac{\theta^{y_1 + \ldots + y_n}}{y_1! \ldots y_n!} e^{-n\theta} \right)$$

$$= \left(\sum_{i=1}^{n} y_i \right) \log \theta - n\theta - \log(y_1! \ldots y_n!)$$





Definition 2.4 (Score-Funktion)

Die Funktion

$$S(\theta) = S(\theta; y_1, \ldots, y_n) = \frac{\partial}{\partial \theta} \ell(\theta; y_1, \ldots, y_n)$$

heißt ***Score-Funktion***.

- lässt sich auch direkt mit Hilfe der Likelihood-Funktion ausdrücken:

$$S(\theta) = \frac{\partial}{\partial \theta} \log \mathcal{L}(\theta; y_1, \ldots, y_n)$$

$$= \frac{1}{\mathcal{L}(\theta; y_1, \ldots, y_n)} \frac{\partial}{\partial \theta} \mathcal{L}(\theta; y_1, \ldots, y_n) = \frac{\frac{\partial}{\partial \theta} \mathcal{L}(\theta)}{\mathcal{L}(\theta}$$

Beispiel: Poisson-Verteilung

$$S(\theta) = S(\theta \vdots y_1, \ldots, y_n) = \frac{\partial}{\partial \theta} \left(\left(\sum_{i=1}^{n} y_i \right) \log \theta - n\theta - \log(y_1! \ldots y_n!) \right)$$
$$= \frac{(\sum_{i=1}^{n} y_i)}{\theta} - n$$

- Durch Nullsetzen kommem wir zur *Score-Gleichung*:

$$0 = S(\theta) = S(\theta \vdots y_1, \ldots, y_n)$$

- Die Lösung dieser Score-Gleichung ist hoffentlich unsere gesuchte Maximalstelle.

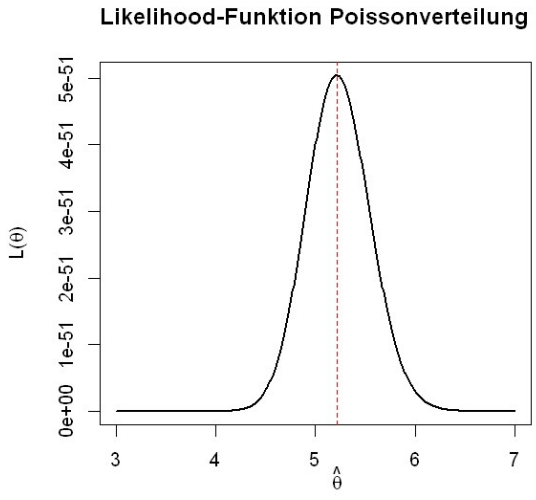
Beispiel: Poisson-Verteilung

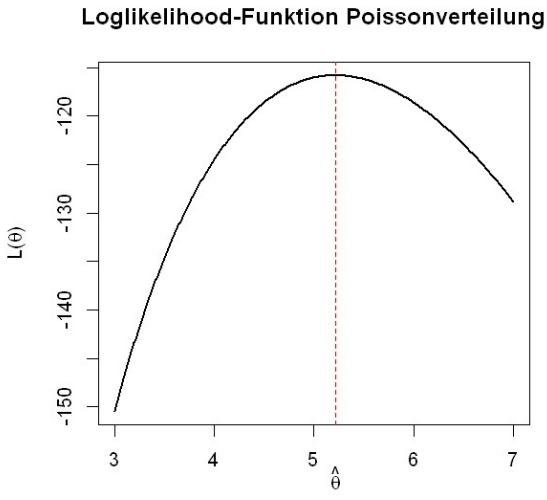
$$0 = S(\theta) = \frac{(\sum_{i=1}^{n} y_i)}{\theta} - n$$
$$\theta = \frac{(\sum_{i=1}^{n} y_i)}{n}$$

- Maximum-Likelihood-Schätzung für den unbekannten Parameter θ:

$$\hat{\theta} = \frac{(\sum_{i=1}^{n} y_i)}{n}$$

- *Überprüfung der Maximaleigenschaft!*





- plausible Schätzung für θ, da:

$$\theta = I\!E_\theta Y_i$$

- unbekannter Erwartungswert wird durch arithmetisches Mittel konkreter Beobachtungen geschätzt

- *ABER:* Es gilt auch:

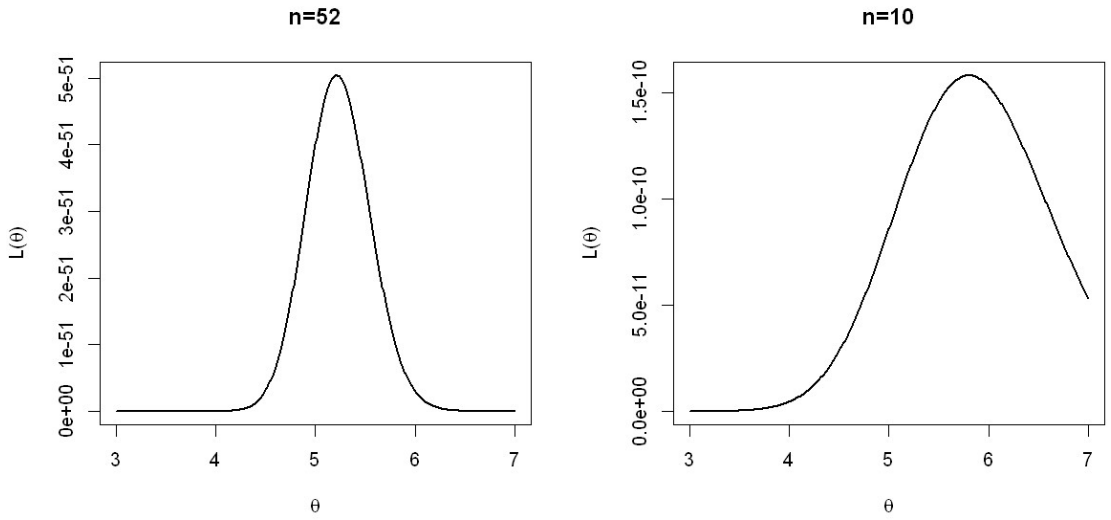
$$\theta = Var_\theta(Y_i)$$

- alternative heuristische Schätzung:

$$\tilde{\theta} = \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2 \qquad \text{(empirische Varianz)}$$

Ist das arithmetische Mittel $\hat{\theta} = \frac{1}{n}\sum_{i=1}^{n} y_i$ oder die empirische Varianz $\tilde{\theta} = \frac{1}{n-1}\sum_{i=1}^{n}(y_i - \bar{y})^2$ der bessere Schätzwert für θ ?

Wie genau ist die Maximum-Likelihood-Schätzung für θ?



- je "schärfer" das Maximum, desto genauer die Schätzung

- brauchen ein Maß für die Krümmung der (Log-)Likelihood-Funktion in der Umgebung der Maximalstelle

2.3 Fisher-Information

Definition 2.5: (Fisher-Information)

Die Funktion

$$I(\theta) = I(\theta; y_1, \ldots, y_n) = -\frac{\partial^2}{\partial\theta^2}\ell(\theta) = -\frac{\partial^2}{\partial\theta^2}\log\mathcal{L}(\theta)$$

heißt ***Fisher-Information***.

Der Wert

$$I(\hat{\theta}) = I(\hat{\theta}; y_1, \ldots, y_n) = -\frac{\partial^2}{\partial \theta^2} \ell(\theta)_{|\theta=\hat{\theta}}$$

heißt ***beobachtete Fisher-Information***.

Bemerkung: $I(\theta) = -\frac{\partial}{\partial \theta} S(\theta)$

Beispiel: Poissonverteilung

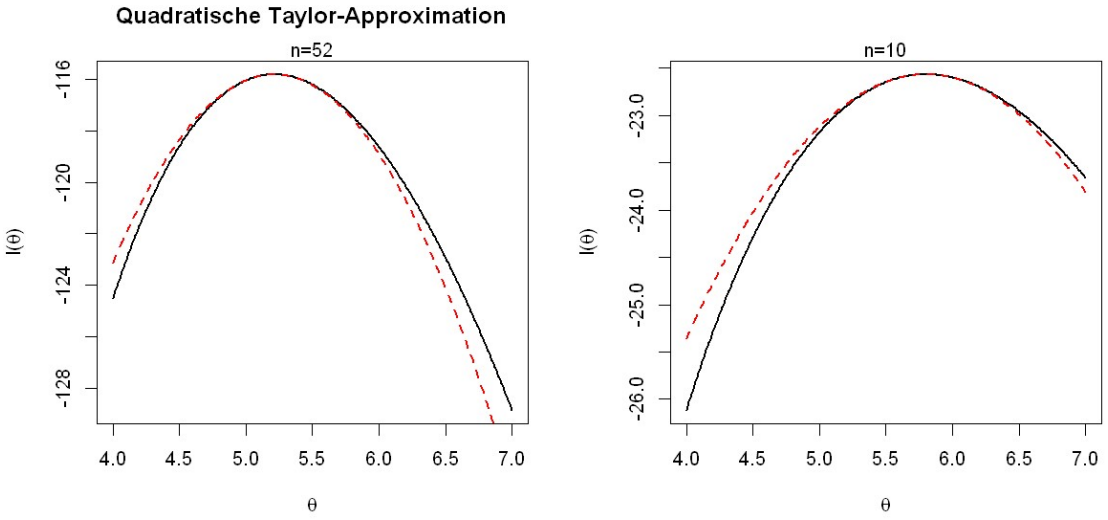
- Fisher-Information

$$\begin{aligned} I(\theta) &= -\frac{\partial^2}{\partial \theta^2} \ell(\theta) = -\frac{\partial}{\partial \theta} S(\theta) \\ &= -\frac{\partial^2}{\partial \theta^2} \left[\left(\sum_{i=1}^{n} y_i \right) \log \theta - n\theta - \log(y_1! \ldots y_n!) \right] \\ &= -\frac{\partial}{\partial \theta} \left(\frac{\sum_{i=1}^{n} y_i}{\theta} - n \right) \\ &= \frac{\sum_{i=1}^{n} y_i}{\theta^2} \end{aligned}$$

Beispiel: Poissonverteilung

- beobachtete Fisher-Information

$$I(\hat{\theta}) = \frac{\sum_{i=1}^{n} y_i}{\hat{\theta}^2} = \frac{\sum_{i=1}^{n} y_i}{\left(\frac{\sum_{i=1}^{n} y_i}{n} \right)^2} = \frac{n^2}{\sum_{i=1}^{n} y_i}$$



2.4 Statistische Eigenschaften der Maximum-Likelihood-Methode

- bisher:
  - Anwendung einer heuristischen Idee für konkrete beobachtete Daten $y_1, \dots, y_n$
  - analytische Maximierung der Funktion $\mathcal{L}(\theta; y_1, \dots, y_n)$

- keine Möglichkeit der Evaluierung des Ergebnisses, da wahrer Wert θ unbekannt

- Wie bewährt sich die Methode bei häufiger Anwendung in vergleichbaren Situationen?

- Ersetzen konkrete Beobachtungen $y_1, \dots, y_n$ durch Modellvorstellung über potentielle Beobachtungen
  $\longrightarrow$ Zufallsgrößen $Y_1, \dots, Y_n$

$y_1, \dots, y_n$	$Y_1, \dots, Y_n$
Likelihood-Funktion	**Likelihood-Funktion**
$\mathcal{L}(\theta; y_1, \dots, y_n)$	$\mathcal{L}(\theta; Y_1, \dots, Y_n)$
für feste Beobachtungen	zufällige Funktion von θ
Funktion von θ	für festes θ Zufallsgröße
Loglikelihood-Funktion	**Loglikelihood-Funktion**
$\ell(\theta; y_1, \dots, y_n)$	$\ell(\theta; Y_1, \dots, Y_n)$
für feste Beobachtungen	zufällige Funktion von θ
Funktion von θ	für festes θ Zufallsgröße

Score-Funktion	**Score-Statistik**
$S(\theta; y_1, \dots, y_n)$	$S(\theta; Y_1, \dots, Y_n)$
für feste Beobachtungen	
Funktion von θ	für festes θ Zufallsgröße
Maximum-Likelihood-Schätzung	**Maximum-Likelihood-Schätzer**
$\hat{\theta}(y_1, \dots, y_n)$	$\hat{\theta}(Y_1, \dots, Y_n)$
relle Zahl	Zufallsgröße

- Wir interessieren uns für die statistischen Eigenschaften der Zufallsgröße $\hat{\theta}(Y_1, \dots, Y_n)$ — des **Maximum-Likelihood-Schätzers**
- Erwartungswert, Verzerrung, Varianz

Beispiel: Patientenankünfte

- konkrete Beobachtungen: $y_1 = 3, y_2 = 6, \dots, y_{52} = 4$

- Maximum-Likelihood-**Schätzung**

$$\hat{\theta} = \hat{\theta}(y_1, \ldots, y_n) = \frac{1}{n} \sum_{i=1}^{n} y_i = 5.21$$

- statistisches Modell

$$Y_i \sim Poisson(\theta) \qquad , \; i = 1, \ldots, n \; , \qquad \text{stochastisch unabhängig}$$

- Maximum-Likelihood-**Schätzer**

$$\hat{\theta} = \hat{\theta}(Y_1, \ldots, Y_n) = \frac{1}{n} \sum_{i=1}^{n} Y_i$$

Beispiel: Patientenankünfte - statistische Eigenschaften des Maximum-Likelihood-Schätzers

- Erwartungswert des ML-Schätzers:

$$\begin{aligned} I\!E \hat{\theta}(Y_1, \ldots, Y_n) = I\!E_\theta \hat{\theta}(Y_1, \ldots, Y_n) &= I\!E_\theta \left(\frac{1}{n} \sum_{i=1}^{n} Y_i \right) \\ &= \frac{1}{n} \sum_{i=1}^{n} I\!E_\theta Y_i \\ &= \frac{1}{n} \sum_{i=1}^{n} \theta \\ &= \theta \end{aligned}$$

- Maximum-Likelihood-Schätzer ist (in diesem Modell) erwartungstreu.

Beispiel: Patientenankünfte - statistische Eigenschaften des ML-Schätzers

- Varianz des ML-Schätzers:

$$\begin{aligned} Var(\hat{\theta}(Y_1, \ldots, Y_n)) = Var_\theta(\hat{\theta}(Y_1, \ldots, Y_n)) &= Var_\theta \left(\frac{1}{n} \sum_{i=1}^{n} Y_i \right) \\ = \frac{1}{n^2} Var_\theta \left(\sum_{i=1}^{n} Y_i \right) \qquad &\underbrace{=}_{\text{Unabh.}} \frac{1}{n^2} \sum_{i=1}^{n} Var_\theta(Y_i) = \frac{\theta}{n} \end{aligned}$$

- Ist dies eine kleine oder eine große Varianz?

- Ist der Maximum-Likelihood-Schätzer in diesem Modell vielleicht *effizient*, d.h. besitzt er die kleinstmögliche Varianz?

2.5 Rao-Cramér-Ungleichung

- Wie genau kann ein Schätzer prinzipiell sein?

- Beobachtungen
$$y_1, \dots, y_n$$
- interpretiert als konkrete Realisierungen von
$$Y_1, \dots, Y_n \ , \qquad Y_i \sim P_\theta \ , \ \theta \in \Theta \ , \ \text{ stoch. unabhängig}$$

- gemeinsame Dichte/Wahrscheinlichkeits-Funktion:
$$f_{(Y_1,\dots,Y_n)}(y_1, \dots, y_n) \underbrace{=}_{\text{Unabh.}} f_{Y_1}(y_1) \dots f_{Y_n}(y_n)$$

Erwartungswert und Varianz der Score-Statistik

$$\begin{aligned} I\!E S(\theta \dot{:} Y_1, \dots Y_n) &= I\!E_\theta S(\theta \dot{:} Y_1, \dots Y_n) \\ &= I\!E_\theta \frac{\partial}{\partial \theta} \ell(\theta \dot{:} Y_1, \dots Y_n) = I\!E_\theta \frac{\frac{\partial}{\partial \theta} \mathcal{L}(\theta \dot{:} Y_1, \dots Y_n)}{\mathcal{L}(\theta \dot{:} Y_1, \dots Y_n)} \end{aligned}$$

$$= \int \frac{\frac{\partial}{\partial \theta} \mathcal{L}(\theta \dot{:} y_1, \dots y_n)}{\mathcal{L}(\theta \dot{:} y_1, \dots y_n)} f_{(Y_1,\dots,Y_n)}(y_1, \dots, y_n) dy_1 \dots dy_n$$

$$\underbrace{=}_{\mathcal{L} \equiv f_{(Y_1,\dots,Y_n)}} \int \frac{\partial}{\partial \theta} \mathcal{L}(\theta \dot{:} y_1, \dots y_n) dy_1 \dots dy_n$$

Erwartungswert und Varianz der Score-Statistik

- Nicht immer, aber unter *Regularitätsbedingungen* sind Integration und Differentiation vertauschbar

$$I\!E_\theta S(\theta \dot{:} Y_1, \dots Y_n) = \frac{\partial}{\partial \theta} \underbrace{\int \mathcal{L}(\theta \dot{:} y_1, \dots y_n) dy_1 \dots dy_n}_{= 1 (\text{ Integral über Dichte})}$$

$$= 0$$

Erwartungswert und Varianz der Score-Statistik

- auf analoge Art und Weise lässt sich auch die Varianz der Score-Statistik bestimmen

Lemma 1.1 Unter *Regularitätsbedingungen* gilt für die Score-Statistik:

- $I\!E_\theta S(\theta \vdots Y_1, \dots Y_n) = 0$
- $Var_\theta S(\theta \vdots Y_1, \dots Y_n) = I\!E_\theta \left(-\frac{\partial^2}{\partial \theta^2} \ell(\theta \vdots Y_1, \dots, Y_n) \right)$

Definition 2.6 (erwartete Fisher-Information)

- Die Größe
$$F(\theta) = I\!E_\theta \left(-\frac{\partial^2}{\partial \theta^2} \ell(\theta \vdots Y_1, \dots, Y_n) \right)$$
heißt ***erwartete Fisher-Information***.

Bemerkung:

- *beobachtete* Fisher-Information $I(\hat{\theta})$:

  Maß für die "Schärfe" des Maximums für eine konkrete Loglikelihood-Funktion für Beobachtungen $y_1, \dots, y_n$
- *erwartete* Fisher-Information $F(\theta)$:

  durchschnittlich zu erwartende "Schärfe" des Maximums für potentielle Beobachtungen $Y_1, \dots, Y_n$, wenn θ der wahre Wert des unbekannten Parameters ist

Lemma 2.2: (Cauchy-Schwarz-Ungleichung für Erwartungswerte)

Es seien X und Y Zufallsgrößen mit existierenden $2.$ Momenten. Dann gilt:
$$(I\!EXY)^2 \leq I\!EX^2 \; I\!EY^2 \; .$$

- für Vektoren:
$$| < x, y > | \leq \|x\| \; \|y\|$$
- für Integrale:
$$\left(\int f(x) g(x) dx \right)^2 \leq \int f^2(x) dx \int g^2(x) dx$$

Folgerung:

Es seien X und Y Zufallsgrößen mit existierenden $2.$ Momenten. Dann gilt:
$$cov(X, Y) \leq \sqrt{Var(X) \; Var(Y)} \; .$$

Beweis:

Wir setzen $X^* = X - I\!EX$ und $Y^* = Y - I\!EY$ und wenden die Cauchy-Schwarzsche Ungleichung an:
$$(I\!E(X - I\!EX)(Y - I\!EY))^2 \leq I\!E(X - I\!EX)^2 I\!E(Y - I\!EY)^2$$

also
$$cov(X, Y)^2 \leq Var(X) \; Var(Y) \; .$$

Satz 2.1 (Rao-Cramér-Schranke)

Es sei $\tilde{\theta}$ ein beliebiger erwartungstreuer Schätzer für den unbekannten Parameter θ in einem statistisches Modell $Y_i \sim P_\theta, \theta \in \Theta, i = 1, \ldots, n$, stochastisch unabhängig. Dann gilt unter *Regularitätsbedingungen* (die die Vertauschung von Differentiation und Integration erlauben):

$$Var_\theta(\tilde{\theta}) \geq \frac{1}{F(\theta)}$$

wobei $F(\theta)$ die erwartete Fisher-Information ist.

Beweis: (nur für den Fall $n = 1$)

Wir betrachten die Score-Statistik (Zufallsgröße!)

$$S(\theta) = S(\theta \vdots Y_1) = \frac{\partial}{\partial \theta} \ell(\theta \vdots Y_1) = \frac{\partial}{\partial \theta} \log \mathcal{L}(\theta \vdots Y_1) = \frac{\partial}{\partial \theta} \log f_\theta(Y_1)$$

Für die Kovarianz zwischen der Score-Statistik $S(\theta \vdots Y_1)$ und dem erwartungstreuen Schätzer $\tilde{\theta} = \tilde{\theta}(Y_1)$ gilt:

$$cov(S(\theta), \tilde{\theta})^2 \leq Var(S(\theta)) Var(\tilde{\theta})$$

Für die linke Seite gilt:

$$\begin{aligned} cov(S(\theta), \tilde{\theta})^2 &= \left[I\!E_\theta (S(\theta) - \underbrace{I\!E_\theta S(\theta)}_{=0}) (\tilde{\theta} - I\!E_\theta \tilde{\theta}) \right]^2 \\ &= \left[I\!E_\theta (S(\theta)\ \tilde{\theta} - S(\theta) \underbrace{I\!E_\theta \tilde{\theta}}_{=\theta}) \right]^2 \\ &= \left[I\!E_\theta S(\theta)\ \tilde{\theta} - \underbrace{I\!E_\theta S(\theta)}_{=0} \theta \right]^2 \\ &= \left[I\!E_\theta S(\theta)\ \tilde{\theta} \right]^2 \end{aligned}$$

$$\begin{aligned} cov(S(\theta), \tilde{\theta})^2 &= \left[\int_{-\infty}^{\infty} S(\theta \vdots y) \tilde{\theta}(y) f_\theta(y) dy \right]^2 \\ &= \left[\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \log \mathcal{L}(\theta \vdots y) \tilde{\theta}(y) f_\theta(y) dy \right]^2 \\ &= \left[\int_{-\infty}^{\infty} \frac{\frac{\partial}{\partial \theta} \mathcal{L}(\theta \vdots y)}{\mathcal{L}(\theta \vdots y)} \tilde{\theta}(y) \underbrace{f_\theta(y)}_{=\mathcal{L}(\theta)} dy \right]^2 \\ &= \left[\int_{-\infty}^{\infty} \frac{\partial}{\partial \theta} \mathcal{L}(\theta \vdots y) \tilde{\theta}(y) dy \right]^2 \end{aligned}$$

- Unter *Regularitätsbedingungen* lassen sich Integration und Differentiation vertauschen

$$\begin{aligned} cov(S(\theta), \tilde{\theta})^2 &= \frac{\partial}{\partial \theta} \left[\int_{-\infty}^{\infty} \underbrace{\mathcal{L}(\theta \dot{:} y)}_{f_\theta(y)} \tilde{\theta}(y) dy \right]^2 \\ &= \left[\frac{\partial}{\partial \theta} I\!E_\theta \tilde{\theta} \right]^2 \\ &= \left[\frac{\partial}{\partial \theta} \theta \right]^2 \\ &= 1 \end{aligned}$$

- Fügen wir nun die rechte Seite der Ungleichung wieder hinzu:

$$1 = cov(S(\theta), \tilde{\theta})^2 \leq Var_\theta(S(\theta)) \, Var_\theta(\tilde{\theta})$$

- Damit ergibt sich:

$$Var_\theta(\tilde{\theta}) \geq \frac{1}{Var_\theta(S(\theta))} = \frac{1}{F(\theta)}$$

Beispiel: Patientenankünfte (Poisson-Verteilung)

- Für den Maximum-Likelihood-Schätzer $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n Y_i$ hatten wir Erwartungstreue gezeigt und

$$Var_\theta(\hat{\theta}) = \frac{\theta}{n}$$

- Außerdem hatten wir die Fisher-Information

$$I(\theta \dot{:} y_1, \ldots, y_n) = -\frac{\partial^2}{\partial \theta^2} \ell(\theta \dot{:} y_1, \ldots, y_n) = \frac{\sum_{i=1}^n y_i}{\theta^2}$$

- Für die erwartete Fisher-Information gilt daher:

$$F(\theta) = I\!E_\theta \left(-\frac{\partial^2}{\partial \theta^2} \ell(\theta \dot{:} Y_1, \ldots, Y_n) \right) = I\!E_\theta \frac{\sum_{i=1}^n Y_i}{\theta^2} = \frac{n}{\theta}$$

- im Beispiel gilt:
  - der ML-Schätzer ist erwartungstreu
  - der ML-Schätzer besitzt die kleinstmögliche Varianz
  - der ML-Schätzer ist *effizient*