3. Das klassische lineare Regressionsmodell

3.1 Modellformulierung

Daten:

- $y_i, i = 1, \dots, n$: Beobachtungen der Zielgröße
- $x_{i2}, \dots, x_{ik}$: Beobachtungen der zugehörigen Einflussgrößen

$$(y_i, x_{i2}, \dots, x_{ik}) \in \mathbb{R}^k \qquad i = 1, \dots, n, \qquad k\text{-Tupel von Beobachtungen}$$

Modellansatz:

- Zwischen den Einflussgrößen und der Zielgröße besteht im Wesentlichen ein linearer funktioneller Zusammenhang

$$y_i \approx \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} \qquad i = 1, \dots, n$$

- y_i werden interpretiert als Realisierungen von Zufallsgrößen Y_i:

$$Y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i \qquad i = 1, \dots, n$$

- unbekannte, aber feste *Regressionskoeffizienten* $\beta_1, \dots, \beta_k$
- zufällige, nicht direkt beobachtbare Abweichungen ε_i vom linearen Zusammenhang

Modell:

deterministischer Teil:

- deterministischer Zusammenhang zwischen Einflussgrößen und Erwartungswert der Zielgröße

$$\mathbb{E}Y_i = \mu_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} \qquad i = 1, \dots, n$$

stochastischer Teil:

- Annahmen über die stochastische Verteilung der Zielgrößen

$$Y_i \sim \mathcal{N}(\mu_i, \sigma^2) \qquad i = 1, \dots, n$$

$$Y_i \text{ stochastisch unabhängig}$$

Alternative Formulierung:

$$Y_i = \beta_1 + \beta_2 x_{i2} + \dots + \beta_k x_{ik} + \varepsilon_i \qquad i = 1, \dots, n$$

- ε_i stochastischer Fehlerterm:

$$\varepsilon_i \sim \mathcal{N}(0, \sigma^2) \qquad i = 1, \dots, n, \qquad \text{stochastisch unabhängig}$$

Matrizenschreibweise:

$$\begin{aligned} Y_1 &= \beta_1 + \beta_2 x_{12} + \ldots + \beta_k x_{1k} + \varepsilon_1 \\ Y_2 &= \beta_1 + \beta_2 x_{22} + \ldots + \beta_k x_{2k} + \varepsilon_2 \\ &\vdots \\ Y_n &= \beta_1 + \beta_2 x_{n2} + \ldots + \beta_k x_{nk} + \varepsilon_n \end{aligned}$$

$$\begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & x_{12} & \ldots & x_{1k} \\ 1 & x_{22} & \ldots & x_{2k} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n2} & \ldots & x_{nk} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

$$\underline{Y} = \mathbb{X}\underline{\beta} + \underline{\varepsilon}$$

Statistisches Modell in Matrizenschreibweise

$$\underline{Y} = \underbrace{\mathbb{X}}_{\text{Design-Matrix}} \underbrace{\underline{\beta}}_{\text{Parametervektor}} + \underline{\varepsilon}$$

deterministischer Teil:

$$\mathbb{E}\underline{Y} = \mathbb{X}\underline{\beta} \qquad \text{mit } \mathbb{X} \in \mathbb{R}^{n \times k}, rang(\mathbb{X}) = k, \underline{\beta} \in \mathbb{R}^k$$

stochastischer Teil:

$$\underline{Y} \sim \mathcal{N}\left(\mathbb{X}\underline{\beta}, \sigma^2 \mathbb{I}_n\right)$$

Bemerkungen:

- Design-Matrix $\mathbb{X}$:
  - nicht zufällig
  - bei geplanten Experimenten (*experimental design*) kann die Design-Matrix gezielt gewählt werden
  - aus $rang(\mathbb{X}) = k$ folgt insbesondere $n \geq k$
  - Falls $rang(\mathbb{X}) < k$ sind die Spalten von $\mathbb{X}$ linear abhängig und die Darstellung

    $$\beta_1 + \beta_2 x_{i2} + \ldots + \beta_k x_{ik}$$

    ist nicht eindeutig.
  - $rang(\mathbb{X}) = k$ kann erreicht werden, indem linear abhängige Spalten entfernt werden.

- Design-Matrix $\mathbb{X}$:
  - Notation:

$$\mathbb{X} = \begin{pmatrix} 1 & x_{12} & \ldots & x_{1k} \\ 1 & x_{22} & \ldots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n2} & \ldots & x_{nk} \end{pmatrix} = \begin{pmatrix} \underline{x}_1^T \\ \underline{x}_2^T \\ \vdots \\ \underline{x}_n^T \end{pmatrix} = \left(\underline{x}^{(1)}, \underline{x}^{(2)}, \ldots, \underline{x}^{(k)}\right)$$

Zeilenvektoren : $\underline{x}_i = \begin{pmatrix} 1 \\ x_{i2} \\ \vdots \\ x_{ik} \end{pmatrix}$ Spaltenvektoren: $\underline{x}^{(1)} = \mathbb{1}_n = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \underline{x}^{(j)} = \begin{pmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{pmatrix}$

- alternative Modellformulierung:

deterministischer Teil:

$$\mathbb{E}Y_i = \underline{x}_i^T \underline{\beta} \qquad i = 1, \ldots, n$$

stochastischer Teil:

$$Y_i \sim \mathcal{N}\left(\underline{x}_i^T \underline{\beta}, \sigma^2\right), \qquad \text{stoch. unabhängig}$$

- Normalverteilung:
  - Häufig sinnvolle Verteilungsannahme auf Grund des *Zentralen Grenzwertsatzes*
  - aber andere Verteilungen sind möglich $\longrightarrow$ *Verallgemeinerte lineare Modelle*

- Unabhängigkeit:
  - macht vor allem das Rechnen viel einfacher
  - sinnvoll, wenn Beobachtungen der Zielgröße auf *unabhängigen* Messungen beruhen, d.h. eine Messung beinhaltet keine Information über weitere Messungen
  - verletzt zum Beispiel bei Mehrfachmessungen an gleichem Objekt/Subjekt oder räumlicher Nähe der Messpunkte
  - statistische Modelle für *stochastisch abhängige* Beobachtungen sind wichtiges Teilgebiet der Statistik, aber nicht Gegenstand dieser Vorlesung

- Varianzhomogenität
  - σ^2 hängt nicht vom Index i ab
  - alle Beobachtungen der Zielgröße sind durch gleichen Grad an Unsicherheit gekennzeichnet
  - keine Möglichkeit der Unterscheidung von genaueren und ungenaueren Beobachtungen

3.2 Zufallsvektoren

Wir betrachten die eindimensionalen reellwertigen Zufallsgrößen

$$Y_1, \ldots, Y_n$$

Diese fassen wir wir zu einem *Zufallsvektor* zusammen:

$$\underline{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}$$

Die Verteilung des Zufallsvektors $\underline{Y}$ ist durch die *Verteilungsfunktion* eindeutig charakterisiert:

$$F_{\underline{Y}}(t_1, \ldots, t_n) = P\left(Y_1 \leq t_1, \ldots, Y_n \leq t_n\right)$$

Verteilungen *stetiger* Zufallsvektoren sind eindeutig durch eine n-dimensionale *Dichtefunktion* charakterisiert:

$$P(\underline{Y} \in B) = \int_B \underbrace{f_{\underline{Y}}(y_1, \dots, y_n)}_{\text{Dichtefunktion}} dy_1 \dots dy_n$$

Verteilungen *diskreter* Zufallsvektoren sind durch ihre *Wahrscheinlichkeitsfunktion* eindeutig charakterisiert.

$$p_{\underline{Y}}(y_1, \dots, y_n) = P(Y_1 = y_1, \dots, Y_n = y_n)$$

Wahrscheinlichkeiten werden durch Aufsummieren dieser Einzelwahrscheinlichkeiten berechnet:

$$P(\underline{Y} \in B) = \sum_{(y_1,\dots,y_n)\in B} p_{\underline{Y}}(y_1, \dots, y_n)$$

Erwartungswertvektor

Falls für alle Komponenten $Y_i, i = 1, \dots, n$ des Zufallsvektors $\underline{Y}$ die Erwartungswerte $I\!EY_i$ existieren, dann heißt

$$I\!E\underline{Y} = \begin{pmatrix} I\!EY_1 \\ \vdots \\ I\!EY_n \end{pmatrix}$$

Erwartungswertvektor des Zufallsvektors $\underline{Y}$.

Kovarianzmatrix

Falls für alle Komponenten $Y_i, i = 1, \dots, n$ gilt $I\!EY_i^2 < \infty$, dann existieren die Varianzen

$$Var(Y_i) = I\!E(Y_i - I\!EY_i)^2$$

und die Kovarianzen

$$cov(Y_i, Y_j) = I\!E(Y_i - I\!EY_i)(Y_j - I\!EY_j)\ i, j = 1, \dots, n$$

Diese werden in der *Kovarianzmatrix*

$$Cov(\underline{Y}) = \Sigma_{\underline{Y}} = \left(cov(Y_i, Y_j)\right)_{i,j=1,\dots,n}$$

zusammengefasst.

Diagonalelemente sind die Varianzen

$$Var(Y_i) = cov(Y_i, Y_i)$$

Es gilt:

$$Cov(\underline{Y}) = I\!E\left[\begin{pmatrix} Y_1 - I\!EY_1 \\ \vdots \\ Y_n - I\!EY_n \end{pmatrix} \begin{pmatrix} Y_1 - I\!EY_1 & \dots & Y_n - I\!EY_n \end{pmatrix}\right]$$

$$= I\!E\left[(\underline{Y} - I\!E\underline{Y})(\underline{Y} - I\!E\underline{Y})^T\right]$$

(*dyadisches Produkt, tensorielles Produkt*)

Eigenschaften der Kovarianzmatrix

- $\Sigma_{\underline{Y}}$ ist symmetrisch

$$cov(Y_i, Y_j) = cov(Y_j, Y_i) \qquad \text{(Symmetrie der Kovarianz)}$$

Eigenschaften der Kovarianzmatrix

- $\Sigma_{\underline{Y}}$ ist positiv semidefinit

$$\text{z.z.:} \qquad \forall \underline{x} \in \mathbb{R}^n : \qquad \underline{x}^T \Sigma_{\underline{Y}} \underline{x} \geq 0$$

Es gilt:

$$\underline{x}^T \Sigma_{\underline{Y}} \underline{x} = \underline{x}^T I\!E \left[(\underline{Y} - I\!E\underline{Y})(\underline{Y} - I\!E\underline{Y})^T \right] \underline{x}$$

$$= I\!E \left[\underbrace{\underline{x}^T (\underline{Y} - I\!E\underline{Y})}_{1\times 1} \underbrace{(\underline{Y} - I\!E\underline{Y})^T \underline{x}}_{1\times 1} \right]$$

$$= I\!E \left(\underline{x}^T (\underline{Y} - I\!E\underline{Y}) \right)^2 \geq 0$$

Rechenregeln

Lemma 3.1: (Lineare Transformation von Zufallsvektoren)

Es sei $\underline{Y}$ ein n - dimensionaler Zufallsvektor mit existierendem Erwartungswertvektor $I\!E\underline{Y}$ und Kovarianzmatrix $\Sigma_{\underline{Y}}$. Ferner seien A eine $(m \times n)$-Matrix und $\underline{b} \in \mathbb{R}^m$. Dann gilt für den transformierten Zufallsvektor $\underline{Z} = A\underline{Y} + \underline{b}$:

- $I\!E\underline{Z}$ und $Cov(\underline{Z})$ existieren
- $I\!E\underline{Z} = I\!E(A\underline{Y} + \underline{b}) = A(I\!E\underline{Y}) + \underline{b}$
- $Cov(\underline{Z}) = Cov(A\underline{Y} + \underline{b}) = A\Sigma_{\underline{Y}} A^T$

n - dimensionale Normalverteilung

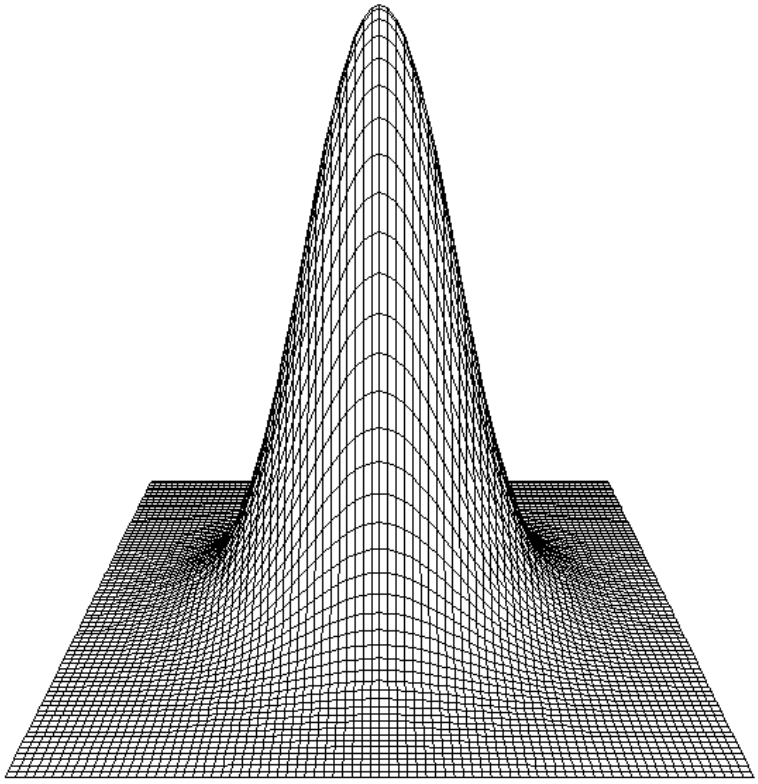
Definition 3.1

Der n-dimensionale Zufallsvektor $\underline{Y}$ besitzt eine (reguläre) *Normalverteilung* mit Erwartungswertvektor $\underline{\mu} \in \mathbb{R}^n$ und Kovarianzmatrix Σ, falls er die folgende Dichtefunktion besitzt:

$$f_{\underline{Y}}(\underline{t}) = \frac{1}{(2\pi)^{n/2}\sqrt{\det \Sigma}} \exp\left\{ -\frac{1}{2} (\underline{t} - \underline{\mu})^T \Sigma^{-1} (\underline{t} - \underline{\mu}) \right\}$$

Bezeichnung: $\underline{Y} \sim \mathcal{N}\left(\underline{\mu}, \Sigma\right)$

Dichtefunktion der zweidimen. Normalverteilung



Lineare Transformation normalverteilter Zufallsvektoren

Satz 3.2.

Es seien $\underline{Y} \sim \mathcal{N}\left(\underline{\mu}, \Sigma\right)$ ein n-dimensionaler normalverteilter Zufallsvektor, A eine reguläre $(n \times n)$-Matrix und $\underline{b} \in \mathbb{R}^n$. Dann gilt:

$$A\underline{Y} + \underline{b} \sim \mathcal{N}\left(A\underline{\mu} + \underline{b}, A\Sigma A^T\right)$$

Folgerung:

Es sei $\underline{Y} \sim \mathcal{N}\left(\underline{\mu}, \Sigma\right)$. Dann existiert eine Matrix P derart, dass

$$\underline{Z} = P\underline{Y} \sim \mathcal{N}\left(P\underline{\mu}, \begin{pmatrix} 1 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 1 \end{pmatrix}\right) \quad = \quad \mathcal{N}\left(P\underline{\mu}, \mathbb{I}_n\right)$$

Beweis:

Die reelle symmetrische Kovarianzmatrix Σ ist diagonalisierbar. Sie lässt sich in der Form

$$\Sigma = S\Lambda S^T$$

darstellen, wobei $\Lambda = diag(\lambda_1, \dots, \lambda_n)$ die Diagonalmatrix der Eigenwerte ist und S die orthogonale Matrix aus den Eigenvektoren.

Wegen der positiven Semidefinitheit sind die Eigenwerte darüber hinaus nichtnegativ und es gilt

$$\Sigma = S\Lambda^{1/2}\Lambda^{1/2}S^T$$

Mit der Transformationsmatrix

$$P = \Lambda^{-1/2}S^T$$

gilt daher:

$$\begin{aligned} Cov(P\underline{Y}) &= Cov(\Lambda^{-1/2}S^T\underline{Y}) \\ &= \Lambda^{-1/2}S^T\ \Sigma\ S\Lambda^{-1/2} \\ &= \Lambda^{-1/2}S^T\ S\Lambda^{1/2}\Lambda^{1/2}S^T\ S\Lambda^{-1/2} \\ &= \mathbb{I}_n \end{aligned}$$

3.3 Maximum-Likelihood-Schätzung im klassischen linearen Modell

Statistisches Modell:

deterministischer Teil:

$$\mathbb{E}\underline{Y} = \mathbb{X}\underline{\beta} \qquad \text{mit } \mathbb{X} \in \mathbb{R}^{n\times k}, rang(\mathbb{X}) = k, \underline{\beta} \in \mathbb{R}^k$$

stochastischer Teil:

$$Y_i \ \sim\ \mathcal{N}\left(\underline{x}_i^T\ \underline{\beta}, \sigma^2\right) \qquad \text{stochastisch unabhängig}$$

$$\underline{Y}\ \sim\ \mathcal{N}\left(\mathbb{X}\underline{\beta}, \sigma^2\mathbb{I}_n\right)$$

Likelihood-Funktion

$$\mathcal{L}(\underline{\beta}) = \mathcal{L}(\underline{\beta}; y_1, \dots, y_n) = \prod_{i=1}^{n} f_{Y_i}(y_i) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \mu_i)^2\right\}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \mu_i)^2 \right\}$$

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left\{ -\frac{1}{2\sigma^2} (\underline{y} - \underline{\mu})^T (\underline{y} - \underline{\mu}) \right\}$$

$$= \frac{1}{(2\pi)^{n/2} det(\Sigma)^{1/2}} \exp\left\{ -\frac{1}{2} (\underline{y} - \underline{\mu})^T \Sigma^{-1} (\underline{y} - \underline{\mu}) \right\} \qquad \text{mit } \Sigma = \sigma^2 \mathbb{I}_n$$

Loglikelihood-Funktion

$$\ell(\underline{\beta}) = \ell(\underline{\beta} \vdots y_1, \dots, y_n) = \sum_{i=1}^{n} \log f_{Y_i}(y_i)$$

$$= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \underline{x}_i^T \underline{\beta})^2$$

$$= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2} (\underline{y} - \underline{\mu})^T (\underline{y} - \underline{\mu})$$

$$= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2} (\underline{y} - \mathbb{X}\underline{\beta})^T (\underline{y} - \mathbb{X}\underline{\beta})$$

Bemerkung:

Wir sehen schon hier, dass die Maximierung der Likelihood-Funktion der Minimierung der Summe der quadratischen Abweichungen entspricht.

Maximierung der Loglikelihood-Funktion

- Nullsetzen aller partiellen Ableitungen, um Maximalstelle zu bestimmen.

- *Score-Funktionen*:

$$S_j(\underline{\beta}) = S_j(\underline{\beta} \vdots, y_1, \dots, y_n) = \frac{\partial \ell(\underline{\beta})}{\partial \beta_j} \qquad , j = 1, \dots, k$$

$$= \frac{\partial}{\partial \beta_j} \left(-\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{n} (y_i - \underline{x}_i^T \underline{\beta})^2 \right)$$

$$= \frac{1}{2\sigma^2} 2 \sum_{i=1}^{n} (y_i - \underline{x}_i^T \underline{\beta}) x_{ij} = \frac{1}{\sigma^2} \underline{x}^{(j)\,T} (\underline{y} - \mathbb{X}\underline{\beta})$$

- Zusammenfassung in vektorwertige *Score-Funktion*:

$$S(\underline{\beta}) = S(\underline{\beta} \vdots \underline{y}) = \frac{\partial \ell(\underline{\beta})}{\partial \underline{\beta}} = \begin{pmatrix} S_1(\underline{\beta}) \\ \vdots \\ S_k(\underline{\beta}) \end{pmatrix}$$

$$= \frac{1}{\sigma^2} \mathbb{X}^T (\underline{y} - \mathbb{X}\underline{\beta})$$

- Alternative Herleitung direkt in Matrizenschreibweise:

$$\ell(\underline{\beta}) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta})$$

$$= -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\left(\underline{y}^T\underline{y} - 2\underline{y}^T\mathbb{X}\underline{\beta} + \underline{\beta}^T\mathbb{X}^T\mathbb{X}\underline{\beta}\right)$$

Differentiationsregeln:

$$\frac{\partial}{\partial \underline{x}} \underline{b}^T \underline{x} = \underline{b}$$

$$\frac{\partial}{\partial \underline{x}} \left(\underline{x}^T A \underline{x}\right) = \left(A + A^T\right) \underline{x}$$

$$\ell(\underline{\beta}) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}\left(\underline{y}^T\underline{y} - 2\underline{y}^T\mathbb{X}\underline{\beta} + \underline{\beta}^T\mathbb{X}^T\mathbb{X}\underline{\beta}\right)$$

$$S(\underline{\beta}) = S(\underline{\beta} \vdots \underline{y}) = -\frac{1}{2\sigma^2}\left(-2\mathbb{X}^T\underline{y} + 2\mathbb{X}^T\mathbb{X}\underline{\beta}\right)$$

Score-Gleichungs-System

$$S(\underline{\beta}) = \underline{\mathbf{o}}_k$$
$$-\frac{1}{2\sigma^2}\left(-2\mathbb{X}^T\underline{y} + 2\mathbb{X}^T\mathbb{X}\underline{\beta}\right) = \underline{\mathbf{o}}_k$$
$$\left(-\mathbb{X}^T\underline{y} + \mathbb{X}^T\mathbb{X}\underline{\beta}\right) = \underline{\mathbf{o}}_k$$

Maximum-Likelihood-Schätzung

- Lösung des Score-Gleichungssystems:

$$\hat{\underline{\beta}} = \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{y}$$

- inverse Matrix existiert, falls $rang(\mathbb{X}) = k$

3.4 Statistische Eigenschaften des Maximum-Likelihood-Schätzers im klassischen linearen Modell

- Maximum-Likelihood-*Schätzung* für konkrete Beobachtungen $y_1, \dots, y_n$:
$$\underline{\hat{\beta}} = \underline{\hat{\beta}}(y_1, \dots, y_n) = \underline{\hat{\beta}}(\underline{y}) = \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{y}$$

- Maximum-Likelihood-*Schätzer* für potentielle Beobachtungen (Zufallsgrößen) $Y_1, \dots, Y_n$:
$$\underline{\hat{\beta}} = \underline{\hat{\beta}}(Y_1, \dots, Y_n) = \underline{\hat{\beta}}(\underline{Y}) = \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{Y}$$

- ML-Schätzer ist lineare Transformation des als normalverteilt angenommenen Vektors $\underline{Y}$ der Zielgrößen

Satz 3.3 (Verteilung des ML-Schätzers)

Im klassischen linearen Regressionsmodell gilt für den ML-Schätzer $\underline{\hat{\beta}}$:

$$\underline{\hat{\beta}} \sim \mathcal{N}\left(\underline{\beta}, \sigma^2(\mathbb{X}^T\mathbb{X})^{-1}\right)$$

Beweis:

Anwendung der Rechenregeln bei linearer Transformation:

$$I\!E\underline{\hat{\beta}} = I\!E\left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{Y} = \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T I\!E\underline{Y}$$

$$= \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\mathbb{X}\underline{\beta}$$

$$= \underline{\beta}$$

$$Cov(\underline{\hat{\beta}}) = Cov\left(\left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{Y}\right)$$

$$= \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T \underbrace{Cov(\underline{Y})}_{=\sigma^2\mathbb{I}_n} \mathbb{X}\left(\mathbb{X}^T\mathbb{X}\right)^{-1}$$

$$= \sigma^2\left(\mathbb{X}^T\mathbb{X}\right)^{-1}$$