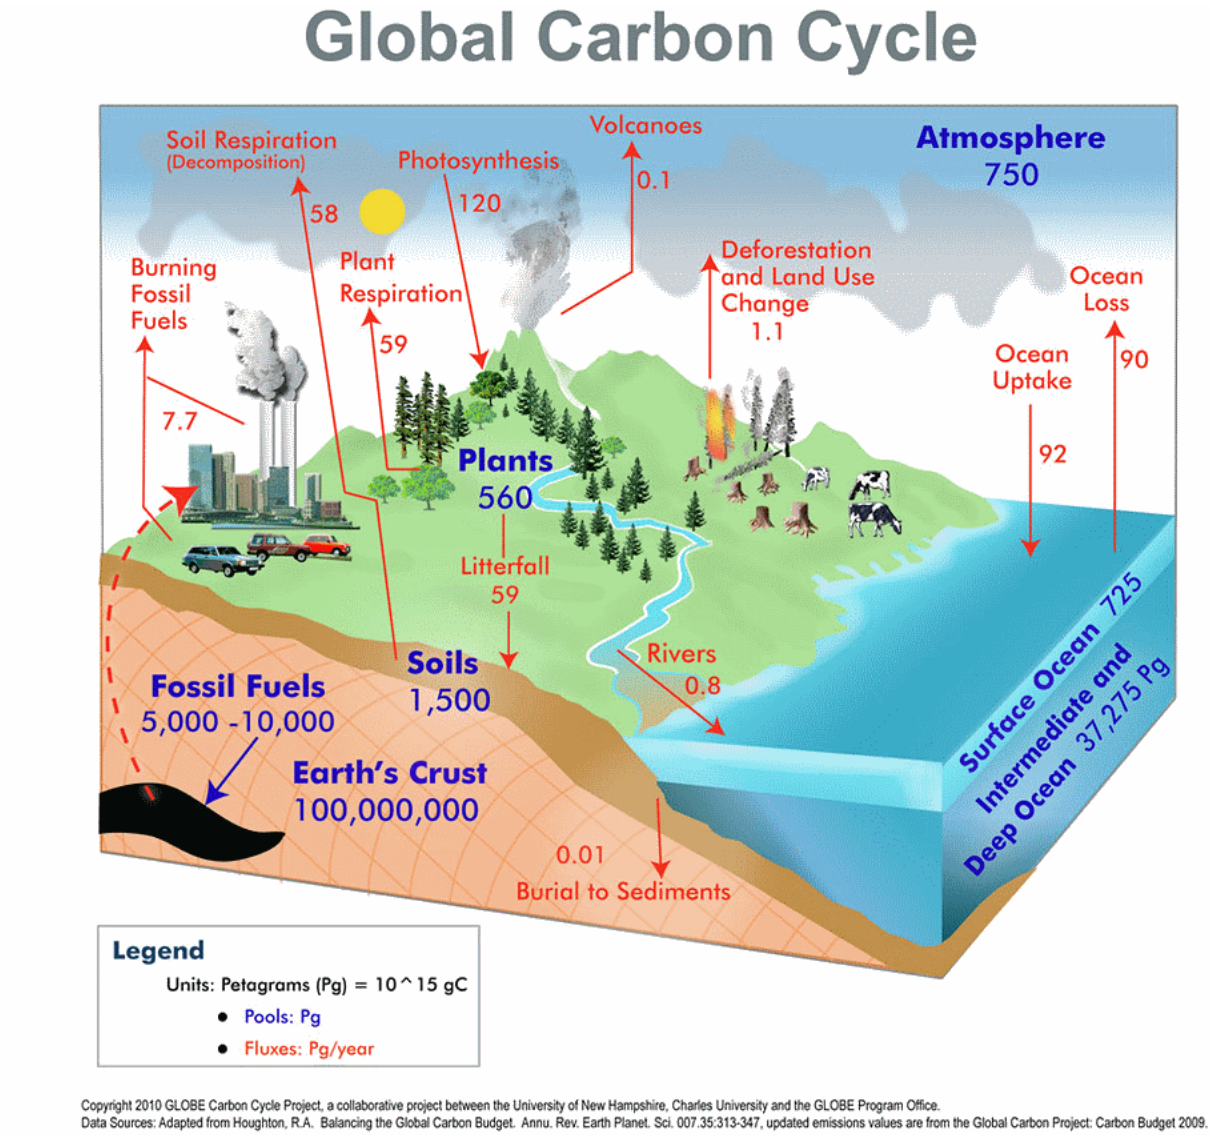
Statistische Verfahren

Dr. Jens Schumacher

1. Einführung

Beispiel 1: Bodenatmung

- wichtiger Aspekt in Klimamodellen



Copyright 2010 GLOBE Carbon Cycle Project, a collaborative project between the University of New Hampshire, Charles University and the GLOBE Program Office.

Data Sources: Adapted from Houghton, R.A. Balancing the Global Carbon Budget. Annu. Rev. Earth Planet. Sci. 007.35:313-347, updated emissions values are from the Global Carbon Project: Carbon Budget 2009.

Beispiel 1: Bodenatmung

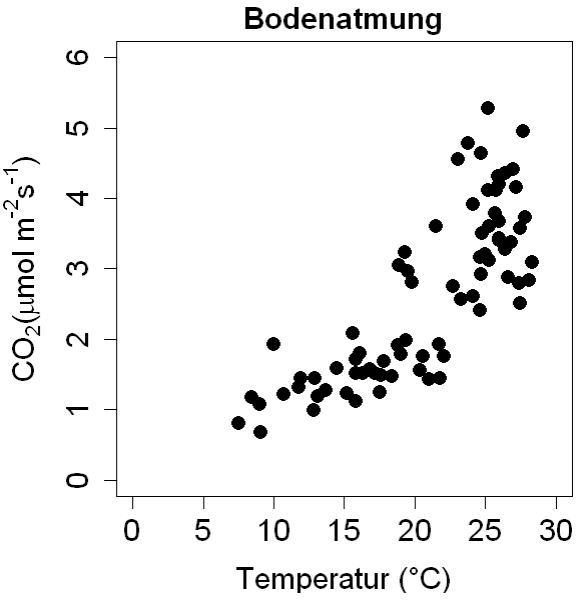
- Austauschprozesse in der Atmosphäre durch deterministische (physikalische) Modelle beschrieben (Differentialgleichungen)

- Die Bodenatmung ist von vielen Faktoren abhängig, darunter der Bodentemperatur und -feuchte, der Menge des vorhandenen organischen Materials und dem Mineralstoffgehalt im Boden.

- Klimabedingte Änderungen der Bodenatmung im Jahresgang überwiegen den Einfluss anderer Faktoren (z. B. Düngemittel oder Pflanzenschutzmittel) oft deutlich.

(Wikipedia-Artikel Bodenatmung, 12.04.2021)

Daten:

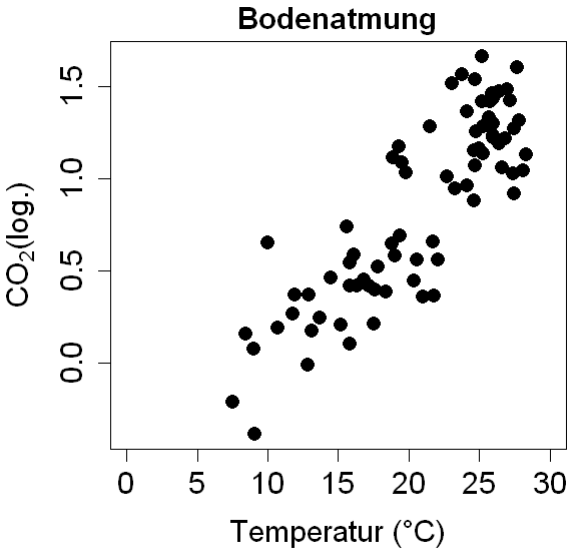


- Variabilität der Bodenatmung selbst bei gleicher Temperatur

- tendentieller Zusammenhang erkennbar

- nichtlinear

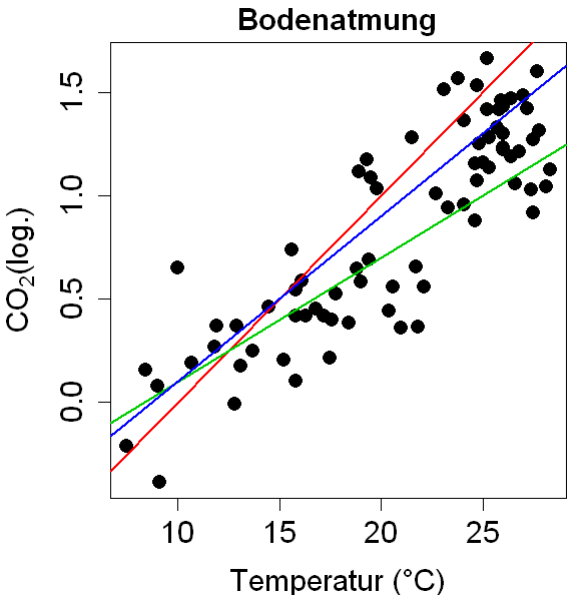
- suchen nach möglichst einfachen Zusammenhängen $\longrightarrow$ Transformation der Zielgröße



- im Wesentlichen linearer Zusammenhang
- suchen beste Kompromiss-Gerade (Ausgleichsgerade)

$$y = \beta_1 + \beta_2 x$$

- Aber wie?



Daten:

$$(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)$$

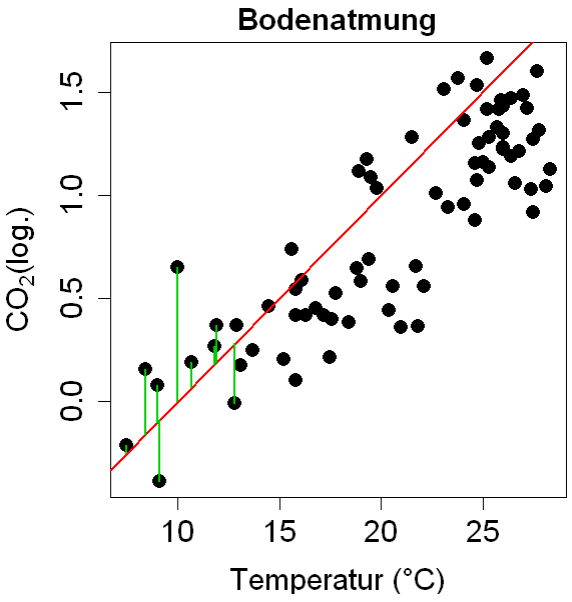
- x_i - beobachteter Wert der ***Einflussgröße***
- y_i - zu x_i gehöriger beobachteter Wert der ***Zielgröße***
- n - Stichprobenumfang

- brauchen Kriterium für die beste Ausgleichsgerade

- $K(\beta_1, \beta_2) = K(\beta_1, \beta_2 \vdots x_1, \dots x_n, y_1, \dots, y_n) = ?$

- Vorschlag: Summe der quadratischen Abweichungen in y-Richtung soll minimal werden

$$K(\beta_1, \beta_2) = \sum_{i=1}^{n} (y_i - (\beta_1 + \beta_2 x_i))^2$$



Wir suchen

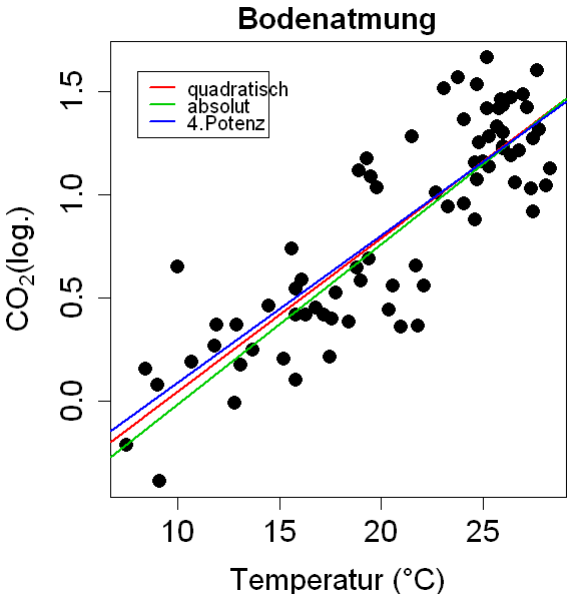
$$\min_{\beta_1, \beta_2} K(\beta_1, \beta_2)$$

- andere Kriterien sind möglich, z.B.

$$K_2(\beta_1, \beta_2) = \sum_{i=1}^{n} |y_i - (\beta_1 + \beta_2 x_i)|$$

$$K_3(\beta_1, \beta_2) = \sum_{i=1}^{n} (y_i - (\beta_1 + \beta_2 x_i))^4$$

- Lösung eines Optimierungsproblems



- Welche Ausgleichsgerade ist die beste?
- Vorstellung: Es gibt einen "wahren" Zusammenhang
- Welche Gerade ist am dichtesten am "wahren" Zusammenhang?
- Frage kann so nicht beantwortet werden, da der "wahre" Zusammenhang nicht bekannt ist.

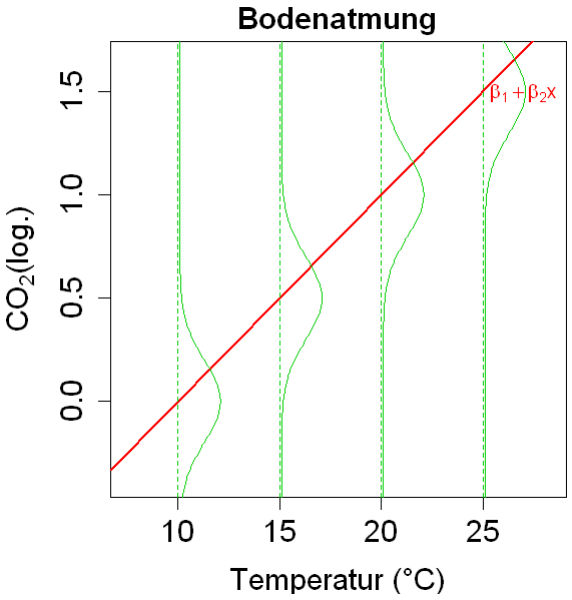
Ausweg: Statistisches Modell

- y_i wird als Realisierung einer Zufallsgröße Y_i aufgefasst
- Linearer Zusammenhang gilt für den Erwartungswert der Zufallsgröße

$$\mathbb{E}Y_i = \mu_i = \beta_1 + \beta_2 x_i \qquad \textit{(deterministischer Teil des Modells)}$$

- Zufallsgröße Y_i besitzt eine zufällige Verteilung

$$Y_i \sim \mathcal{N}(\mu_i, \sigma^2), i = 1, \ldots, n, \text{ stochastisch unabhängig} \quad \textit{(stochastischer Teil des Modells)}$$



Bemerkungen

- Werte der Einflussgrößen x_i werden als nicht zufällig angenommen
  - das ist häufig sinnvoll, z.B. wenn die Einflussgrößen in Experimenten manipuliert werden
  - bei Beobachtungsdaten ist eigentlich eine Betrachtung als zufällig sinnvoller, wir wollen hier vor allem technische stochastische Schwierigkeiten durch bedingte Wahrscheinlichkeiten vermeiden

- $\beta_1, \beta_2 \in \mathbb{R}$:
  - unbekannte, aber feste reelle Parameter ("wahrer" Zusammenhang")
  - wir können β_1, β_2 **nicht** bestimmen/**berechnen**, sondern wollen diese Parameter basierend auf vorliegenden Daten **schätzen**

- häufig besitzen die Parameter β_1, β_2 des Modells eine intuitive Interpretation

Interpretation des Parameters β_2 im Beispiel Bodenatmung

$$r_i - \text{Bodenatmung}, \qquad t_i - \text{Bodentemperatur}$$

$$\log r_i \approx \beta_1 + \beta_2 t_i$$

$$r_i \approx e^{\beta_1+\beta_2 t_i} = e^{\beta_1} e^{\beta_2 t_i} = e^{\beta_1} \left(e^{\beta_2}\right)^{t_i} = e^{\beta_1} \left(e^{10\beta_2}\right)^{t_i/10} = e^{\beta_1} Q_{10}^{t_i/10}$$

$Q_{10} = e^{10\beta_2}$: Faktor, um den sich sich die Bodenatmung ändert, falls die Bodentemperatur um $10^\circ C$ steigt

Bemerkungen

- andere Verteilungsannahmen sind möglich

- Varianzhomogenität: σ^2 (ohne i)
  - Variabilität der betrachteten Zufallsgrößen ist unabhängig von x_i
  - und damit auch vom Erwartungswert $\mathbb{E}Y_i$ der Zielgröße
  - **starke Einschränkung** in der Modellannahme

Was bringt das statistische Modell?

$$\begin{aligned} \mathbb{E}Y_i = \mu_i = \beta_1 + \beta_2 x_i \, , i = 1, \dots, n && \textit{(deterministischer Teil)} \\ Y_i \sim \mathcal{N}(\mu_i, \sigma^2) \, , i = 1, \dots, n \text{ unabhängig} && \textit{(stochastischer Teil)} \end{aligned}$$

- die nach einem ausgewählten Kriterium bestimmten Werte für die Parameter der Ausgleichsgeraden sind **Schätzwerte/Schätzungen** für die wahren unbekannten Werte β_1, β_2:

$$\begin{aligned} \hat{\beta}_1 &= \hat{\beta}_1(y_1, \dots, y_n, x_1, \dots, x_n) = \hat{\beta}_1(y_1, \dots, y_n) \\ \hat{\beta}_2 &= \hat{\beta}_2(y_1, \dots, y_n, x_1, \dots, x_n) = \hat{\beta}_2(y_1, \dots, y_n) \end{aligned}$$

- Wir wissen immer noch nicht, wie nah diese Schätzwerte an den unbekannten wahren Parametern β_1, β_2 dran sind, **ABER:**

- Wir können im Rahmen des Modells typische/statistische Eigenschaften eines ausgewählten Kriteriums untersuchen

- statistische Eigenschaften zeigen sich bei häufiger Anwendung ein und desselben Kriteriums bei vergleichbaren Datensätzen

Statistische Eigenschaften

- die Verteilung der Zufallsgrößen Y_i beschreibt intuitiv, welche Werte die Zielgrößen mit welchen Wahrscheinlichkeiten annehmen kann

- wir können daher (wenigstens gedanklich) die Schätzwerte $\hat{\beta}_1, \hat{\beta}_2$ für alle möglichen Werte der Zielgrößen bestimmen

Dazu ersetzen wir die konkreten Beobachtungen $y_1, \ldots, y_n$ der Zielgröße durch die Zufallsvariablen $Y_1, \ldots, Y_n$ nennen das dann die **Schätzer** für β_1, β_2:

$$\hat{\beta}_1 = \hat{\beta}_1(Y_1, \ldots, Y_n)$$
$$\hat{\beta}_2 = \hat{\beta}_2(Y_1, \ldots, Y_n)$$

$\hat{\beta}_1 = \hat{\beta}_1(Y_1, \ldots, Y_n)$ und $\hat{\beta}_2 = \hat{\beta}_2(Y_1, \ldots, Y_n)$ sind dann auch **Zufallsvariablen**

- **VORSICHT**:
  - $\hat{\beta}_1(y_1, \ldots, y_n)$ ist eine reelle Zahl (**Schätzwert, Schätzung**)
  - $\hat{\beta}_1(Y_1, \ldots, Y_n)$ ist eine Zufallsvariable (**Schätzer**)

- Welche sinnvollen Eigenschaften sollten die Schätzer, also die Zufallsvariablen $\hat{\beta}_1 = \hat{\beta}_1(Y_1, \ldots, Y_n)$ und $\hat{\beta}_2 = \hat{\beta}_2(Y_1, \ldots, Y_n)$ besitzen?

Erwartungstreue

$$\theta - \text{unbekannter reeller Parameter}$$
$$Y_i \sim P_\theta, \theta \in \Theta$$
$$\hat{\theta} = \hat{\theta}(Y_1, \ldots, Y_n) - \text{Schätzer für den unbekannten Parameter} \theta$$

Definition 1.1 (Erwartungstreue)

Ein Schätzer $\hat{\theta} = \hat{\theta}(Y_1, \ldots, Y_n)$ für einen unbekannten Parameter heißt **erwartungstreu**, falls gilt:

$$\mathbb{E}\hat{\theta} = \mathbb{E}_\theta\hat{\theta} = \theta \qquad \text{für alle} \qquad \theta \in \Theta$$

- Bei der Erwartungswertbildung muss natürlich eine stochastische Verteilung zu Grunde gelegt werden. Das Subskript $\mathbb{E}_\theta$ kennzeichnet diese Verteilung: Die Zufallsvariablen $Y_1, \ldots, Y_n$ sollen bei dieser Erwartungswertbildung die im statistischen Modell angenommene Verteilung P_θ besitzen, die von dem unbekannten Parameter θ abhängt.

Varianz

Definition 1.2 (Effizienz) Ein erwartungstreuer Schätzer $\hat{\theta}$ für einen unbekannten Parameter θ heißt **effizient**, falls er unter allen erwartungstreuen Schätzern die kleinste Varianz besitzt, d.h., für jeden anderen erwartungstreuen Schätzer $\tilde{\theta}$ gilt:

$$Var_\theta(\tilde{\theta}) \geq Var_\theta(\hat{\theta})$$

$$Var_\theta(\hat{\theta}) = \mathbb{E}_\theta\left(\hat{\theta} - \mathbb{E}_\theta\hat{\theta}\right)^2 = \mathbb{E}_\theta\left(\hat{\theta} - \theta\right)^2$$

Verzerrung (Bias)

Definition 1.3 (Bias)

Die Größe

$$bias(\hat{\theta}) = \mathbb{E}_\theta(\hat{\theta}) - \theta$$

heißt **Bias/Verzerrung** des Schätzers $\hat{\theta}$.

Quadratisches Risiko (Mean Square Error)

Definition 1.4 (Quadratisches Risiko) Die Größe

$$MSE(\hat{\theta}) = \mathbb{E}_\theta\left(\hat{\theta} - \theta\right)^2$$

heißt **quadratisches Risiko** bzw. **mean square error** des Schätzers $\hat{\theta}$.

- MSE - mean square error

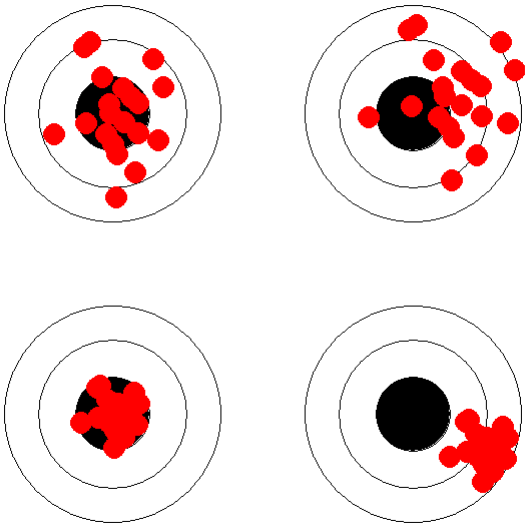
$$\begin{aligned}
MSE(\hat{\theta}) &= \mathbb{E}_\theta\left(\hat{\theta} - \theta\right)^2 \\
&= \mathbb{E}_\theta\left(\hat{\theta} - \mathbb{E}_\theta\hat{\theta} + \mathbb{E}_\theta\hat{\theta} - \theta\right)^2 \\
&= \mathbb{E}_\theta\left(\hat{\theta} - \mathbb{E}_\theta\hat{\theta}\right)^2 + \mathbb{E}_\theta\left(\mathbb{E}_\theta\hat{\theta} - \theta\right)^2 + 2\mathbb{E}_\theta\left(\hat{\theta} - \mathbb{E}_\theta\hat{\theta}\right)\left(\mathbb{E}_\theta\hat{\theta} - \theta\right) \\
&= Var_\theta(\hat{\theta}) + bias(\hat{\theta})^2 + 0 \\
&= Var_\theta(\hat{\theta}) + bias(\hat{\theta})^2
\end{aligned}$$

Fragen

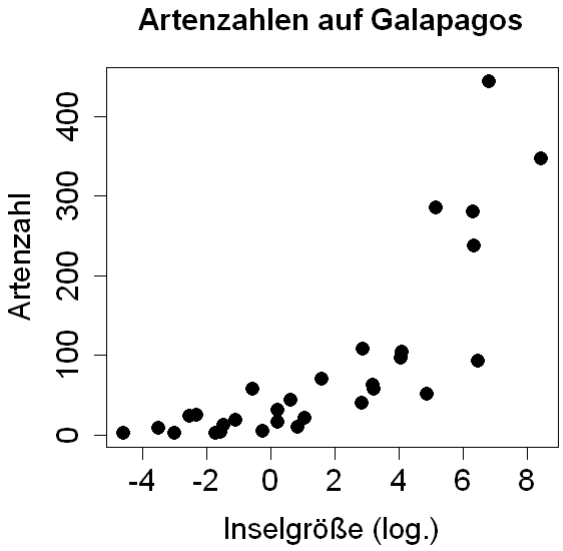
- Wie genau kann ein Schätzer höchstens sein?

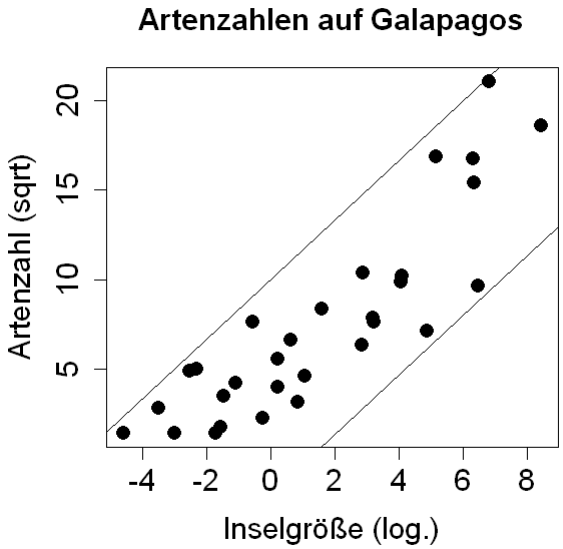
- Gibt es Schätzer, die diese höchste Genauigkeit erreichen?

Verzerrung und Varianz

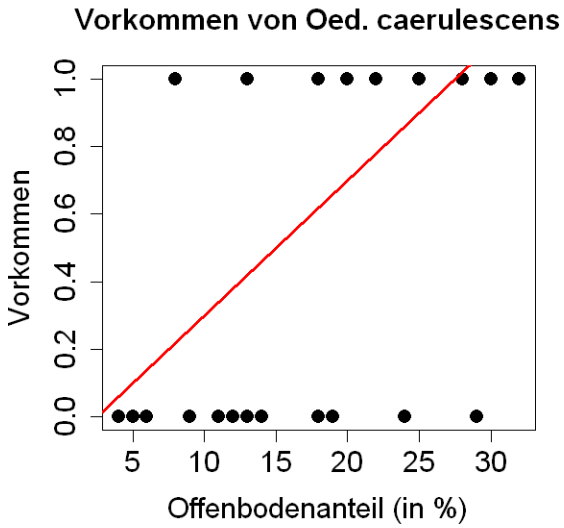


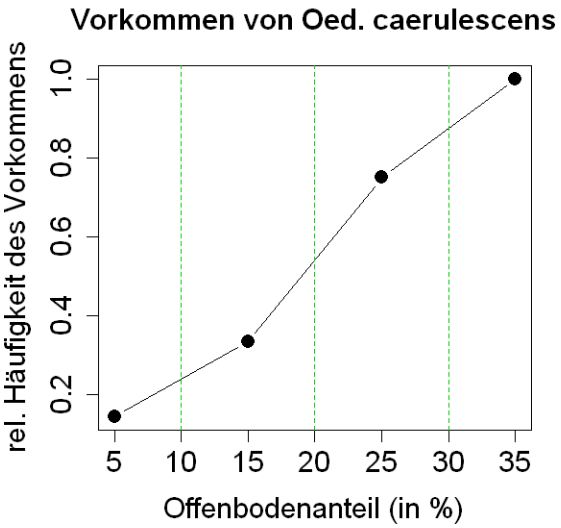
Beispiel 2: Artenzahlen auf Galapagos





Beispiel 3: Vorkommen der blauflügeligen Ödlandschrecke

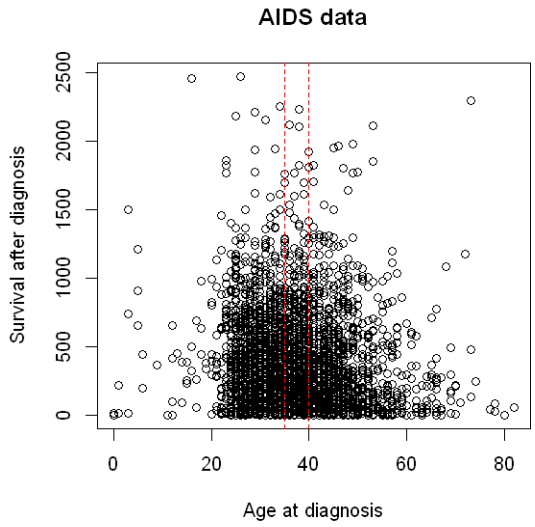


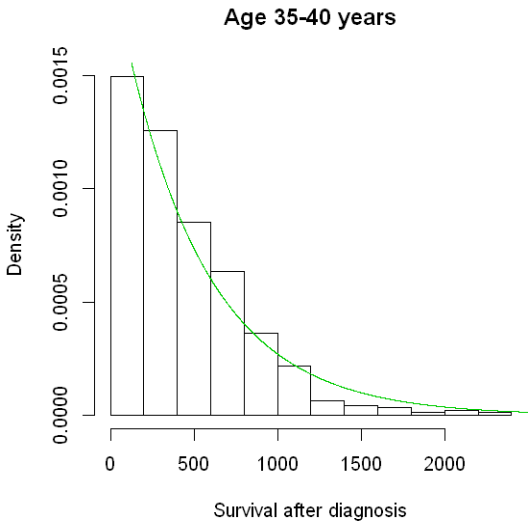


- dichotome Zielgröße Vorkommen/nichtvorkommen: Binomialverteilung $Bin(1, p)$ als stochastische Verteilung
- nichtlinearer Zusammenhang zwischen Offenbodenanteil und Vorkommenswahrscheinlichkeit

Beispiel 4: Überleben mit AIDS

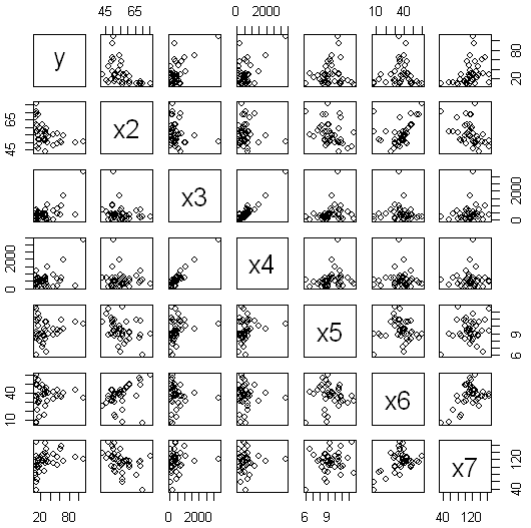
```
Loading required package: MASS
```





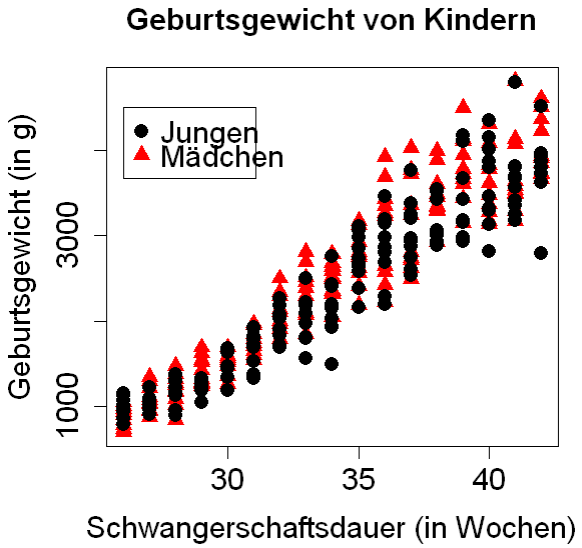
- Exponentialverteilung als stochastische Verteilungsannahme

Beispiel 5: SO_2 - Belastung der Luft

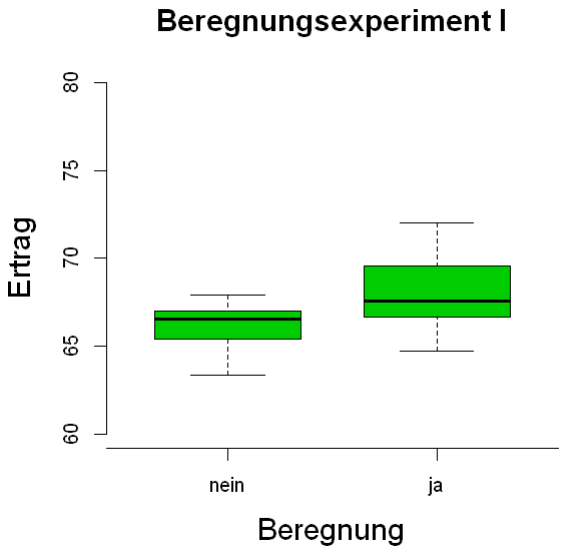


- mehrere Einflussgrößen:
  - Schwierigkeiten bei der Visualisierung
  - der Wert einer Einflussgröße kann den quantitativen Einfluss einer anderen Einflussgröße auf die Zielgröße modifizieren $\longrightarrow$ ***Wechselwirkungen*** zwischen Einflussgrößen
  - welche Einflussgrößen sind wichtig $\longrightarrow$ ***Modellwahl***

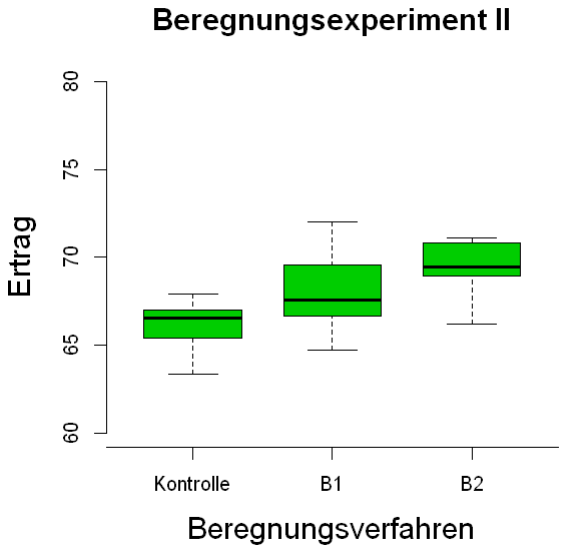
Beispiel 6: Geburtsgewicht von Säuglingen



Beispiel 7: Beregnungsexperiment I



Beispiel 8: Beregnungsexperiment II



Beispiel 9: Beregnungsexperiment III

