3.4 Statistische Eigenschaften des ML-Schätzers im klassischen linearen Modell - Fortsetzung

Modell:

deterministischer Teil:

$$\mathbb{E}Y_i = \mu_i = \beta_1 + \beta_2 x_{i2} + \ldots + \beta_k x_{ik} \qquad i = 1, \ldots, n$$

stochastischer Teil:

$$Y_i \sim \mathcal{N}(\mu_i, \sigma^2) \qquad i = 1, \ldots, n$$

Y_i stochastisch unabhängig

Matrizenschreibweise:

deterministischer Teil:

$$\mathbb{E}Y_i = \underline{x}_i^T \underline{\beta}$$

$$\mathbb{E}\underline{Y} = \mathbb{X}\underline{\beta} \qquad \text{mit } \mathbb{X} \in \mathbb{R}^{n \times k}, rang(\mathbb{X}) = k, \underline{\beta} \in \mathbb{R}^k$$

stochastischer Teil:

$$\underline{Y} \sim \mathcal{N}\left(\mathbb{X}\underline{\beta}, \sigma^2 \mathbb{I}_n\right)$$

- Maximum-Likelihood-Schätzer:

$$\hat{\underline{\beta}} = \hat{\underline{\beta}}(Y_1, \ldots, Y_n) = \hat{\underline{\beta}}(\underline{Y}) = \left(\mathbb{X}^T\mathbb{X}\right)^{-1}\mathbb{X}^T\underline{Y}$$

Verteilung des ML-Schätzers:

$$\hat{\underline{\beta}} \sim \mathcal{N}\left(\underline{\beta}, \sigma^2(\mathbb{X}^T\mathbb{X})^{-1}\right)$$

$\hat{\underline{\beta}}$ ist ein erwartungstreuer Schätzer:

$$\mathbb{E}\hat{\underline{\beta}} = \underline{\beta} \qquad \forall\, \underline{\beta} \in \mathbb{R}^k$$

Prognose: Schätzung des Erwartungswerts der Zielgröße

$$\mathbb{E}Y_i = \underline{x}_i^T \underline{\beta}$$

$$\hat{Y}_i = \widehat{\mathbb{E}Y_i} = \underline{x}_i^T \hat{\underline{\beta}}$$

beziehungweise

$$\mathbb{E}\underline{Y} = \mathbb{X}\underline{\beta}$$

$$\underline{\hat{Y}} = \widehat{I\!E\underline{Y}} = \mathbb{X}\underline{\hat{\beta}} = \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\underline{Y} = \mathbb{H}\underline{Y}$$

- es gilt:

$$I\!E\underline{\hat{Y}} = I\!E\mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\underline{Y}$$

$$= \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T I\!E\underline{Y}$$

$$= \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\mathbb{X}\underline{\beta}$$

$$= \mathbb{X}\underline{\beta}$$

- Die Prognose $\underline{\hat{Y}}$ ist ein erwartungstreuer Schätzer für $I\!E\underline{Y} = \mathbb{X}\underline{\beta}$.

Die Matrix

$$\mathbb{H} = \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T$$

heißt *Hut-Matrix*.

Lemma 3.4. (Eigenschaften der Hut-Matrix)

- $\mathbb{H}$ ist symmetrisch
- $\mathbb{H}$ ist idempotent
- $\mathbb{H}$ besitzt nur die Eigenwerte 0 und 1
- $spur(\mathbb{H}) = rang(\mathbb{H}) = k$
- $\mathbb{I}_n - \mathbb{H}$ ist auch symmetrisch, idempotent und $spur(\mathbb{I}_n - \mathbb{H}) = n - k$

Beweis:

- Symmetrie - klar

- Idempotenz: Eine Matrix $\mathbb{A}$ heißt idempotent, falls $\mathbb{A}\mathbb{A} = \mathbb{A}$.

$$\underbrace{\mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T}_{\mathbb{H}}\underbrace{\mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T}_{\mathbb{H}} = \underbrace{\mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T}_{\mathbb{H}}$$

- Eigenwerte idempotenter Matrizen:

$$\mathbb{H}\underline{x} = \lambda\underline{x}$$
$$\mathbb{H}\underline{x} = \mathbb{H}\mathbb{H}\underline{x} = \mathbb{H}\lambda\underline{x} = \lambda\mathbb{H}\underline{x} = \lambda^2\underline{x}$$

- Spur:

$$spur(\mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T) \overset{spur(AB)=spur(BA)}{=} spur((\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\mathbb{X}) = spur(\mathbb{I}_k) = k$$

Kovarianzmatrix des ML-Schätzers $\hat{\underline{\beta}}$

$$Cov(\hat{\underline{\beta}}) = \sigma^2(\mathbb{X}^T\mathbb{X})^{-1}$$

- Diagonalelemente beschreiben die Genauigkeit der Schätzer für einzelne Komponenten des Parametervektors

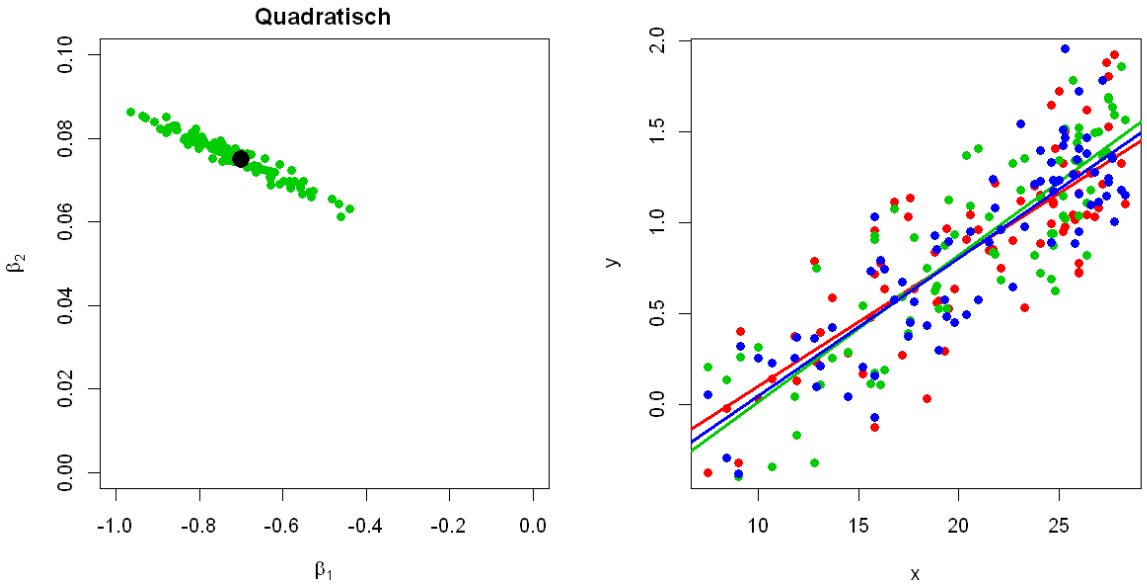
$$Cov(\hat{\underline{\beta}})_{jj} = Var(\hat{\beta}_j)$$

- Off-Diagonalelemente beschreiben die Kovarianz zwischen Schätzern für unterschiedliche Komponenten

$$Cov(\hat{\underline{\beta}})_{jl} = cov(\hat{\beta}_j, \hat{\beta}_l)$$

- diese sind typischerweise von 0 verschieden: Komponenten werden nicht unabhängig voneinander geschätzt
- ABER: Wenn in Experimenten die Designmatrix $\mathbb{X}$ gezielt gewählt werden kann, kann Unabhängigkeit der Schätzer für verschiedene Komponenten erzwungen werden - *experimental design*.

Beispiel: Bodenatmung-Simulation



Was bedeutet in diesem Kontext *kleinste* Kovarianzmatrix?

Definition 3.2

Ein erwartungstreuer Schätzer $\hat{\underline{\beta}}$ für einen k-dimensionalen Parametervektor $\underline{\beta}$ heißt ***effizient***, falls für jeden anderen erwartungstreuen Schätzer $\tilde{\underline{\beta}}$ gilt:

$$Cov(\tilde{\underline{\beta}}) - Cov(\hat{\underline{\beta}}) \qquad \text{ist positiv semidefinit}$$

Interpretation:

$$\forall\, \underline{z} \in \mathbb{R}^k : \qquad \underline{z}^T (Cov(\tilde{\underline{\beta}}) - Cov(\hat{\underline{\beta}}))\underline{z} \geq 0$$

$$\underbrace{\underline{z}^T (Cov(\tilde{\underline{\beta}})\underline{z}}_{Cov(\underline{z}^T \tilde{\underline{\beta}})} \geq \underbrace{\underline{z}^T Cov(\hat{\underline{\beta}})\underline{z}}_{Cov(\underline{z}^T \hat{\underline{\beta}})}$$

$$Var(\underline{z}^T \tilde{\underline{\beta}}) \geq Var(\underline{z}^T \hat{\underline{\beta}})$$

- Insbesondere gilt für $\underline{z} = \underline{e}_j$:

$$Var(\underline{e}_j^T \tilde{\underline{\beta}}) \geq Var(\underline{e}_j^T \hat{\underline{\beta}})$$

$$Var(\tilde{\beta}_j) \geq Var(\hat{\beta}_j)$$

- d.h., jede Komponente von $\underline{\beta}$ wird mit $\hat{\underline{\beta}}$ mindestens so genau geschätzt wie mit $\tilde{\underline{\beta}}$

- Definition 3.2 definiert eine *Halbordnung* für Kovarianzmatrizen:

$$Cov(\tilde{\underline{\beta}}) \succcurlyeq Cov(\hat{\underline{\beta}}) \qquad \Leftrightarrow \qquad Cov(\tilde{\underline{\beta}}) - Cov(\hat{\underline{\beta}}) \qquad \text{ist positiv semidefinit}$$

Fishersche Informationsmatrix

Definition 3.3 (Fishersche Informationsmatrix)

- Die Matrix

$$I(\underline{\beta}) = -\frac{\partial^2 \ell(\beta)}{\partial \underline{\beta} \partial \underline{\beta}^T} = \left(-\frac{\partial^2 \ell(\underline{\beta})}{\partial \beta_i \partial \beta_j} \right)_{i,j=1,\ldots,k}$$

heißt ***Fishersche Informationsmatrix***.

- Für konkreten Beobachtungsvektor $\underline{y} = (y_1, \ldots, y_n)$ heißt

$$I(\hat{\underline{\beta}}) = \left(-\frac{\partial^2 \ell(\underline{\beta})}{\partial \underline{\beta} \partial \underline{\beta}^T} \right)_{|\underline{\beta}=\hat{\underline{\beta}}} = \left(-\frac{\partial^2 \ell(\underline{\beta} \vdots \underline{y})}{\partial \underline{\beta} \partial \underline{\beta}^T} \right)_{|\underline{\beta}=\hat{\underline{\beta}}}$$

beobachtete Fishersche-Informationsmatrix.

- Für den Zufallsvektor $\underline{Y} = (Y_1, \ldots, Y_n)$ heißt

$$F(\underline{\beta}) = I\!E_{\underline{\beta}} \left(-\frac{\partial^2 \ell(\underline{\beta})}{\partial \underline{\beta} \partial \underline{\beta}^T} \right) = I\!E_{\underline{\beta}} \left(-\frac{\partial^2 \ell(\underline{\beta} \vdots \underline{Y})}{\partial \underline{\beta} \partial \underline{\beta}^T} \right)$$

erwartete Fishersche-Informationsmatrix.

Satz 3.5. (Rao-Cramér Ungleichung mehrdimensional)

Für jeden erwartungstreuen Schätzer $\tilde{\underline{\beta}}$ für einen unbekannten Parametervektor $\underline{\beta} \in \mathbb{R}^k$ gilt unter Regularitätsbedingungen:

$$Cov(\tilde{\underline{\beta}}) \succcurlyeq F^{-1}(\underline{\beta})$$

Beispiel: Klassisches lineares Modell

$$I\!E\underline{Y} = \mathbb{X}\underline{\beta} \qquad \text{mit } \mathbb{X} \in \mathbb{R}^{n\times k}, rang(\mathbb{X}) = k, \underline{\beta} \in \mathbb{R}^k$$

$$\underline{Y} \sim \mathcal{N}\left(\mathbb{X}\underline{\beta}, \sigma^2 \mathbb{I}_n\right)$$

- Wir hatten die Score-Funktion

$$S(\underline{\beta}) = \frac{\partial \ell(\underline{\beta})}{\partial \underline{\beta}} = -\frac{1}{2\sigma^2}\left(-2\mathbb{X}^T\underline{y} + 2\mathbb{X}^T\mathbb{X}\underline{\beta}\right)$$

- durch nochmaliges Ableiten ergibt sich die Fisher-Informationsmatrix

$$I(\underline{\beta}) = -\frac{\partial^2 \ell(\beta)}{\partial\underline{\beta}\partial\underline{\beta}^T} = \frac{1}{\sigma^2}\mathbb{X}^T\mathbb{X}$$

- unabhängig von $\underline{\beta}$, daher ***beobachtete*** Fisher-Informationsmatrix:

$$I(\widehat{\underline{\beta}}) = \frac{1}{\sigma^2}\mathbb{X}^T\mathbb{X}$$

- Da kein $\underline{y}$ auftaucht, gilt für die ***erwartete*** Fisher-Informationsmatrix

$$F(\underline{\beta}) = I\!E_{\underline{\beta}}\left(-\frac{\partial^2 \ell(\underline{\beta})}{\partial\underline{\beta}\partial\underline{\beta}^T}\right) = \frac{1}{\sigma^2}\mathbb{X}^T\mathbb{X}$$

- Für den ML-Schätzer $\widehat{\underline{\beta}}$ gilt daher:

$$Cov(\widehat{\underline{\beta}}) = \sigma^2\left(\mathbb{X}^T\mathbb{X}\right)^{-1} = F^{-1}(\underline{\beta})$$

- Der ML-Schätzer $\widehat{\underline{\beta}}$ ist effizient, d.h., er ist ein erwartungstreuer Schätzer mit der kleinstmöglichen Kovarianzmatrix **in diesem Modell**

ML-Schätzung des Varianzparameters σ^2

- auch σ^2 ist ein unbekannter Parameter des Modells
- Likelihood-Funktion und Loglikelihood-Funktion hängen auch von σ^2 ab

$$\ell(\underline{\beta}, \sigma^2) = -\frac{n}{2}\log(2\pi) - \frac{n}{2}\log(\sigma^2) - \frac{1}{2\sigma^2}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta})$$

- Maximierung bezüglich $\underline{\beta}$ ist unabhängig von der Maximierung bezüglich σ^2 möglich.

- Score-Funktion bezüglich σ^2:

$$S_{\sigma^2}(\underline{\beta}, \sigma^2) = \frac{\partial \ell(\underline{\beta}, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta})$$

- Score-Gleichung für σ^2:

$$\begin{aligned} 0 &= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta}) \\ \frac{n}{2\sigma^2} &= \frac{1}{2\sigma^4}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta}) \\ \sigma^2 &= \frac{1}{n}(\underline{y} - \mathbb{X}\underline{\beta})^T(\underline{y} - \mathbb{X}\underline{\beta}) \end{aligned}$$

- ML-Schätzung für σ^2:

$$\widehat{\sigma^2} = \frac{1}{n}(\underline{y} - \mathbb{X}\underline{\widehat{\beta}})^T(\underline{y} - \mathbb{X}\underline{\widehat{\beta}})$$

$$\widehat{\sigma^2} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \underline{x}_i^T\underline{\widehat{\beta}})^2$$

- Alternative Darstellungen:

$$\begin{aligned} \widehat{\sigma^2} &= \frac{1}{n}(\underline{y} - \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\underline{y})^T(\underline{y} - \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T\underline{y}) \\ &= \frac{1}{n}\underline{y}^T(\mathbb{I}_n - \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T)^T(\mathbb{I}_n - \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T)\underline{y} \\ &= \frac{1}{n}\underline{y}^T(\mathbb{I}_n - \mathbb{H})\underline{y} \end{aligned}$$

Statistische Eigenschaften des Varianzschätzers

- ML-Schätzer

$$\widehat{\sigma^2} = \widehat{\sigma^2}(\underline{Y}) = \frac{1}{n}(\underline{Y} - \mathbb{X}\underline{\widehat{\beta}})^T(\underline{Y} - \mathbb{X}\underline{\widehat{\beta}})$$

- Erwartungswert:

$$\mathbb{E}\,\widehat{\sigma^2} = \frac{1}{n}\mathbb{E}\,\underbrace{\underline{Y}^T(\mathbb{I}_n - \mathbb{H})\underline{Y}}_{\text{quadratische Form in } \underline{Y}}$$

Lemma 3.6 (Erwartungswert quadratischer Formen)

Es seien $\underline{Y}$ ein n-dimensionaler Zufallsvektor mit Erwartungswertvektor $I\!E\underline{Y} = \underline{\mu}$ und Kovarianzmatrix $Cov(\underline{Y}) = \Sigma$ sowie $\mathbb{A}$ eine $n \times n$-Matrix. Dann gilt:

$$I\!E\underline{Y}^T \mathbb{A}\underline{Y} = \underline{\mu}^T \mathbb{A}\underline{\mu} + spur(\mathbb{A}\Sigma)$$

Beweis:

$$\mathbb{E}\underline{Y}^T \mathbb{A}\underline{Y} = \mathbb{E}(spur(\underline{Y}^T \mathbb{A}\underline{Y}))$$

$$= \mathbb{E}spur(\mathbb{A}\underline{Y}\ \underline{Y}^T)$$

$$= spur(\mathbb{A}\mathbb{E}\underline{Y}\ \underline{Y}^T)$$

$$= spur\left(\mathbb{A}\left[\mathbb{E}(\underline{Y} - \underline{\mu})(\underline{Y} - \underline{\mu})^T + \underline{\mu}\underline{\mu}^T\right]\right)$$

$$= spur(\mathbb{A}\Sigma + \mathbb{A}\underline{\mu}\underline{\mu}^T)$$

$$= spur(\mathbb{A}\Sigma) + spur(\mathbb{A}\underline{\mu}\underline{\mu}^T)$$

$$= spur(\mathbb{A}\Sigma) + spur(\underline{\mu}^T \mathbb{A}\underline{\mu})$$

$$= spur(\mathbb{A}\Sigma) + \underline{\mu}^T \mathbb{A}\underline{\mu}$$

- Damit ergibt sich:

$$I\!E\,\widehat{\sigma^2} = \frac{1}{n}\left[\underbrace{(\mathbb{X}\underline{\beta})^T\ (\mathbb{I}_n - \mathbb{H})\ \mathbb{X}\underline{\beta}}_{=0} + \sigma^2 spur(\mathbb{I}_n - \mathbb{H})\right] = \frac{\sigma^2}{n}(n-k)$$

- ML-Schätzer $\widehat{\sigma^2}$ für σ^2 ist nicht erwartungstreu
- $\widehat{\sigma^2}$ *unterschätzt* tendentiell die wahre Varianz σ^2

- Wir betrachten für wachsenden Stichprobenumfang n die *Folge* der ML-Schätzer $\left\{\widehat{\sigma^2}_{(n)}\right\}$ (k konstant). Dann gilt:

$$\lim_{n\to\infty} I\!E\,\widehat{\sigma^2}_{(n)} = \lim_{n\to\infty} \sigma^2 \frac{n-k}{n} = \sigma^2$$

- Die Folge der Schätzer $\left\{\widehat{\sigma^2}_{(n)}\right\}$ ist ***asymptotisch erwartungstreu***

- $\widehat{\sigma^2}$ kann zu einem erwartungstreuen Schätzer modifiziert werden:

$$\widetilde{\sigma^2} = \frac{n}{n-k}\,\widehat{\sigma^2} = \frac{1}{n-k}(\underline{Y} - \mathbb{X}\underline{\hat{\beta}})^T(\underline{Y} - \mathbb{X}\underline{\hat{\beta}})$$

$$= \frac{1}{n-k}\sum_{i=1}^{n}(Y_i - \underline{x}_i^T\underline{\hat{\beta}})^2 = \frac{1}{n-k}\sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2$$

- im klassischen linearen Modell wird üblicherweise diese erwartungstreue Variante $\widetilde{\sigma^2}$ verwendet.

Alternative Schreibweise

- Modell dargestellt mit zufälligem Fehlerterm:
$$\underline{Y} = \mathbb{X}\underline{\beta} + \underline{\varepsilon} \qquad \text{mit} \qquad \underline{\varepsilon} \sim \mathcal{N}(\mathbf{o}_n, \sigma^2\mathbb{I}_n)$$
bzw.
$$Y_i = \underline{x}_i^T\underline{\beta} + \varepsilon_i \qquad \text{mit} \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \text{ unabhängig}$$

- Die Größe
$$\hat{\varepsilon}_i = Y_i - \hat{Y}_i = Y_i - \underline{x}_i^T\hat{\underline{\beta}}$$
heißt i-tes *Residuum*.

$$\widetilde{\sigma^2} = \frac{1}{n-k}\sum_{i=1}^{n}(Y_i - \widehat{Y}_i)^2 = \frac{1}{n-k}\sum_{i=1}^{n}\hat{\varepsilon}_i^2 = \frac{1}{n-k}\underbrace{RSS}_{\text{residual sum of squares}}$$

Verteilung des erwartungstreuen Varianzschätzers $\widetilde{\sigma^2}$

$$\widetilde{\sigma^2} = \frac{1}{n-k}\underline{Y}^T(\mathbb{I}_n - \mathbb{X}(\mathbb{X}^T\mathbb{X})^{-1}\mathbb{X}^T)\underline{Y}$$

$$= \frac{1}{n-k}\underline{Y}^T(\mathbb{I}_n - \mathbb{H})\underline{Y}$$

$$= \frac{1}{n-k}(\mathbb{X}\underline{\beta} + \underline{\varepsilon})^T(\mathbb{I}_n - \mathbb{H})(\mathbb{X}\underline{\beta} + \underline{\varepsilon})$$

$$= \frac{1}{n-k}\underline{\varepsilon}^T(\mathbb{I}_n - \mathbb{H})\underline{\varepsilon}$$

- die relle, symmetrische, idempotente Matrix $\mathbb{I}_n - \mathbb{H}$ ist diagonalisierbar
$$\mathbb{I}_n - \mathbb{H} = \mathbb{P}^T\,\mathrm{diag}(\underbrace{1, \dots, 1}_{n-k}, 0, \dots, 0)\,\mathbb{P} = \mathbb{P}^T\,\mathbb{D}\,\mathbb{P}$$

- damit ergibt sich

$$\widetilde{\sigma^2} = \frac{1}{n-k}\underline{\varepsilon}^T\mathbb{P}^T\mathbb{D}\underbrace{\mathbb{P}\underline{\varepsilon}}_{=:\underline{Z}} = \frac{1}{n-k}\underline{Z}^T\mathbb{D}\underline{Z} = \frac{1}{n-k}\sum_{i=1}^{n-k} Z_i^2$$

- für den Zufallsvektor $\underline{Z}$ gilt dabei:

$$\underline{Z} = \mathbb{P}\underline{\varepsilon}$$

$$\underline{Z} \sim \mathcal{N}(\mathbb{P}\mathbf{o}_n, \sigma^2\mathbb{P}\mathbb{P}^T) = \mathcal{N}(\mathbf{o}_n, \sigma^2\mathbb{I}_n)$$

- und wir erhalten

$$\widetilde{\sigma^2} = \frac{1}{n-k}\sigma^2\sum_{i=1}^{n-k}\left(\frac{Z_i}{\sigma}\right)^2$$

wobei $\frac{Z_i}{\sigma} \sim \mathcal{N}(0,1)$ unabhängige standardnormalverteilte Zufallsgrößen sind.

Erinnerung: (χ^2-Verteilung)

Es seien $Z_1, \ldots, Z_n$ unabhängige standardnormalverteilte Zufallsgrößen, $Z_i \sim \mathcal{N}(0,1)$. Dann besitzt die transformierte Zufallsgröße

$$Y = \sum_{i=1}^{n} Z_i^2$$

eine χ^2*-Verteilung mit n Freiheitsgraden*.

- Dichte:

$$f_Y(t) = \frac{1}{2^{n/2}\Gamma(n/2)}t^{n/2-1}e^{-t/2} \qquad , t > 0$$

- Momente:

$$I\!E Y = n$$

$$Var(Y) = 2n$$

Satz 3.7 (Verteilung des Varianzschätzers)

Im klassischen linearen Modell gilt für die erwartungstreue Version des ML-Schätzers:

$$(n-k)\frac{\widetilde{\sigma^2}}{\sigma^2} \sim \chi^2_{n-k}$$

Bemerkungen:

- Erwartungstreue noch einmal bestätigt, denn

$$I\!E(n-k)\frac{\widetilde{\sigma^2}}{\sigma^2} = n-k \qquad \Rightarrow \qquad I\!E\,\widetilde{\sigma^2} = \sigma^2$$

- Varianz des Varianzschätzers:

$$Var\left((n-k)\frac{\widetilde{\sigma^2}}{\sigma^2}\right) = 2(n-k) \quad \Rightarrow \quad Var\left(\widetilde{\sigma^2}\right) = \frac{2\sigma^4(n-k)}{(n-k)^2} = \frac{2\sigma^4}{n-k}$$

- Für wachsenden Stichprobenumfang gilt für die Folge der Varianzschätzer $\left\{\widetilde{\sigma^2}_{(n)}\right\}$:

$$\lim_{n\to\infty} Var\left(\widetilde{\sigma^2}_{(n)}\right) = \lim_{n\to\infty} \frac{2\sigma^4}{n-k} = 0$$

- daher gilt auch

$$P\left(\left|\widetilde{\sigma^2}_{(n)} - \sigma^2\right| > \delta\right) \leq \frac{Var(\widetilde{\sigma^2}_{(n)})}{\delta^2} \xrightarrow{n\to\infty} 0$$

- wir sagen:
  - mathematisch:

    Die Folge der Varianzschätzer $\left\{\widetilde{\sigma^2}_{(n)}\right\}$ ist eine ***konsistente*** Folge von Schätzern für σ^2.
  - intuitiv:

    Für beliebig großen Stichprobenumfang kann die Varianz beliebig genau geschätzt werden.

Statistische Anwendung der Verteilungseigenschaften des ML-Schätzers

Satz 3.8

Im klassischen linearen Modell gilt für jeden Vektor $\underline{c} \in \mathbb{R}^k$:

$$\frac{\underline{c}^T\underline{\hat{\beta}} - \underline{c}^T\underline{\beta}}{\sqrt{\widetilde{\sigma^2}\,\underline{c}^T(\mathbb{X}^T\mathbb{X})^{-1}\underline{c}}} \sim t_{n-k}$$

Erinnerung: (t-Verteilung)

Es seien Z und Y unabhängige Zufallsgrößen mit $Z \sim \mathcal{N}(0,1)$ und $Y \sim \chi^2_n$. dann heißt die Verteilung der transformierten Zufallsgröße

$$X = \frac{Z}{\sqrt{Y/n}}$$

t-Verteilung mit n Freiheitsgraden.

- Dichtefunktion:

$$f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\,\Gamma\left(\frac{n}{2}\right)}\left(1+\frac{x^2}{n}\right)^{-\frac{n+1}{2}}$$

- Momente:
  - Für $n > 1$ gilt:
$$\mathbb{E}X = 0$$
  - Für $n > 2$ gilt:
$$Var(X) = \frac{n}{n-2}$$

Beweis von Satz 3.8:

- Zähler:
$$\underline{c}^T \underline{\hat{\beta}} - \underline{c}^T \underline{\beta} \sim \mathcal{N}\left(\underline{c}^T \underline{\beta} - \underline{c}^T \underline{\beta}, \underline{c}^T Cov(\underline{\hat{\beta}}) \underline{c}\right) = \mathcal{N}\left(0, \sigma^2 \underline{c}^T (\mathbb{X}^T \mathbb{X})^{-1} \underline{c}\right)$$
$$\frac{\underline{c}^T \underline{\hat{\beta}} - \underline{c}^T \underline{\beta}}{\sqrt{\sigma^2 \underline{c}^T (\mathbb{X}^T \mathbb{X})^{-1} \underline{c}}} \sim \mathcal{N}(0,1)$$

- Nenner:
$$(n-k)\frac{\widetilde{\sigma^2}}{\sigma^2} \sim \chi^2_{n-k} \qquad \Rightarrow \qquad \frac{\widetilde{\sigma^2}}{\sigma^2} \sim \frac{1}{n-k}\chi^2_{n-k}$$

- Unabhängigkeit: ohne Beweis