3.5 Modellwahl im klassischen linearen Modell

- bisher: Modellwahl basierend auf statistischen Tests
- Argumentation:
  - ***Wenn*** das Modell (H_0) richtig ist, ***dann*** besitzt unsere Test-Statistik eine bestimmte Verteilung
  - ***Wenn*** die Test-Statistik einen extrem ungewöhnlichen Wert annimmt, ***dann*** entscheiden wir uns gegen unser einfaches Modell (H_0) und wählen ein komplizierteres

3.5.2 Modellwahl zur Minimierung des erwarteten Prognosefehlers

- Prognose der Zielgröße häufig primäres Ziel der statistischen Modellbildung

- Ungenauigkeit der Prognose bisher beschrieben durch $(1-\alpha)$-Prognoseintervalle

- Prognoseintervalle sind nur verlässlich, ***falls das zu Grunde liegende Modell richtig ist***

- was passiert, wenn ich ein falsches Modell zur Prognose verwende?

- im Unterschied zu bisher gehen wir deshalb jetzt davon aus, dass wir das *wahre* Modell nicht kennen

> **All models are wrong, but some are useful.**

(Box: Empirical Model-Building and Response Surfaces)

- wir betrachten im Moment nur klassische lineare Modelle, aber Ideen sind verallgemeinerbar

Modellvorstellung

Stochastischer Teil:

$$Y_i \sim \mathcal{N}(\mu_i, \sigma^2)\ i = 1, \dots, n$$

- unabhängige Zufallsgrößen, die die Variabilität der Zielgröße modellieren

Deterministischer Teil:

$$\{1, x_{i2}, \dots, x_{ik}\} \qquad i = 1, \dots, n$$

- potentielle Einflussgrößen

- **nicht vergessen!!!** - können Transformationen und Interaktionen beinhalten
- Die Spaltenvektoren $\underline{x}^{(j)}$, $j = 1, \dots, k$ bilden die Spalten der maximalen Design-Matrix $\mathbb{X}$

- Kandidatenmodelle sind durch eine Auswahl von potentiellen Einflussgrößen gekennzeichnet
- identifizierbar durch eine Indexmenge $M = \left\{j_1, \dots, j_{|M|}\right\} \subseteq \{1, \dots, k\}$ mit dazugehöriger Designmatrix

$$\mathbb{X}_M = \left(\underline{x}^{(j_1)}, \dots, \underline{x}^{(j_{|M|})}\right)$$

- **Kandidatenmodell M:**

$$\mathbb{E}\underline{Y} = \underline{\mu} = \mathbb{X}_M \underline{\beta}^{(M)}$$

- keines dieser Kandidatenmodelle muss das *wahre* Modell sein

- trotzdem können wir in jedem Kandidatenmodell:
  - den Parametervektor $\underline{\beta}^{(M)}$ schätzen:

$$\underline{\hat{\beta}}^{(M)} = \left(\mathbb{X}_M^T \mathbb{X}_M\right)^{-1} \mathbb{X}_M^T \underline{Y}$$

- und
  - den Erwartungswert der Zielgröße schätzen:

$$\underline{\hat{Y}}^{(M)} = \widehat{\mathbb{E}\underline{Y}}^{(M)} = \mathbb{X}_M \underline{\hat{\beta}}^{(M)} = \mathbb{X}_M \left(\mathbb{X}_M^T \mathbb{X}_M\right)^{-1} \mathbb{X}_M^T \underline{Y}$$

- da die Kandidatenmodelle falsch sein können, haben diese Schätzer nicht mehr notwendigerweise die gewohnten wünschenswerten Eigenschaften, insbesondere müssen sie nicht mehr erwartungstreu sein
  - mit einem falschen Modell können unsere Prognosen systematisch daneben liegen

$$\mathbb{E}\underline{\hat{Y}}^{(M)} = \underline{\mu}^{(M)} \neq \underline{\mu}$$

- von den Prognose-Intervallen wissen wir, dass selbst beim *wahren* Modell die Vorhersagegenauigkeit vom Vektor der Einflussgrößen $\underline{x}$ abhängt

- es gibt also nicht ***den*** Prognosefehler

- Ziel ist es, den Prognosefehler zu minimieren für Werte der Einflussgrößen, die denen im vorliegenden Datensatz vergleichbar sind

Erwarteter Prognosefehler:

Y_{i+n} – neue zukünftige Beobachtung zum selben Einflussvektor $\underline{x}_i$ wie die Beobachtung Y_i

$$SEP^{(M)} = \mathbb{E}\left(\sum_{i=1}^{n}\left(Y_{i+n} - \hat{Y}_i^{(M)}\right)^2\right)$$

- SEP - *S*quared *E*rror of *P*rediction
- Summation über n neue Beobachtungen
- andere Kenngrößen für den Prognosefehler:

$$MSEP^{(M)} = \frac{1}{n} SEP^{(M)} \qquad \textit{(Mean Squared Error of Prediction)}$$

$$RMSEP^{(M)} = \sqrt{MSEP^{(M)}} = \sqrt{\frac{1}{n} SEP^{(M)}} \qquad \textit{(Root Mean Squared Error of Prediction)}$$

Zerlegung des Prognosefehlers:

$$\begin{aligned}
SEP^{(M)} &= \sum_{i=1}^{n} \mathbb{E}(Y_{n+i} - \mu_i + \mu_i - \hat{Y}_i^{(M)})^2 \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \hat{Y}_i^{(M)})^2 + 2\mathbb{E}(Y_{n+i} - \mu_i)(\mu_i - \hat{Y}_i^{(M)}) \right] \\
&\overset{\text{unabh.}}{=} \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \hat{Y}_i^{(M)})^2 + 2\underbrace{\mathbb{E}(Y_{n+i} - \mu_i)}_{=0}\mathbb{E}(\mu_i - \hat{Y}_i^{(M)}) \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \hat{Y}_i^{(M)})^2 \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \mu_i^{(M)} + \mu_i^{(M)} - \hat{Y}_i^{(M)})^2 \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \mu_i^{(M)})^2 + \mathbb{E}(\mu_i^{(M)} - \hat{Y}_i^{(M)})^2) + 2\mathbb{E}(\mu_i - \mu_i^{(M)})(\mu_i^{(M)} - \hat{Y}_i^{(M)}) \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \mu_i^{(M)})^2 + \mathbb{E}(\mu_i^{(M)} - \hat{Y}_i^{(M)})^2 + 2\mathbb{E}(\mu_i - \mu_i^{(M)})(\mu_i^{(M)} - \hat{Y}_i^{(M)}) \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \mu_i^{(M)})^2 + \mathbb{E}(\mu_i^{(M)} - \hat{Y}_i^{(M)})^2 + 2(\mu_i - \mu_i^{(M)})\underbrace{\mathbb{E}(\mu_i^{(M)} - \hat{Y}_i^{(M)})}_{=0} \right] \\
&= \sum_{i=1}^{n} \left[\mathbb{E}(Y_{n+i} - \mu_i)^2 + \mathbb{E}(\mu_i - \mu_i^{(M)})^2 + \mathbb{E}(\mu_i^{(M)} - \hat{Y}_i^{(M)})^2 \right] \\
&= \sum_{i=1}^{n} \mathbb{E}(Y_{n+i} - \mu_i)^2 + \sum_{i=1}^{n} (\mu_i - \mu_i^{(M)})^2 + \sum_{i=1}^{n} \mathbb{E}(\hat{Y}_i^{(M)} - \mu_i^{(M)})^2
\end{aligned}$$

Interpretation der Bestandteile des Prognosefehlers:

- **1.Term:**

$$\sum_{i=1}^{n} \mathbb{E}(Y_{n+i} - \mu_i)^2 = \sum_{i=1}^{n} Var(Y_{n+i}) = \sum_{i=1}^{n} Var(Y_i) = n\sigma^2$$

  - ***irreduzibler Prognosefehler***
  - verursacht durch Variabilität der Zielgröße
  - unabhängig vom konkreten Kandidatenmodell M

- **2.Term:**

$$\sum_{i=1}^{n}(\mu_i - \mu_i^{(M)})^2 = \sum_{i=1}^{n}(bias_i^{(M)})^2$$

  - ***Bias-Term***
  - hängt vom Kandidatenmodell M ab
  - tendenziell sinkt der Bias mit der Anzahl der im Modell enthaltenen Einflussgrößen

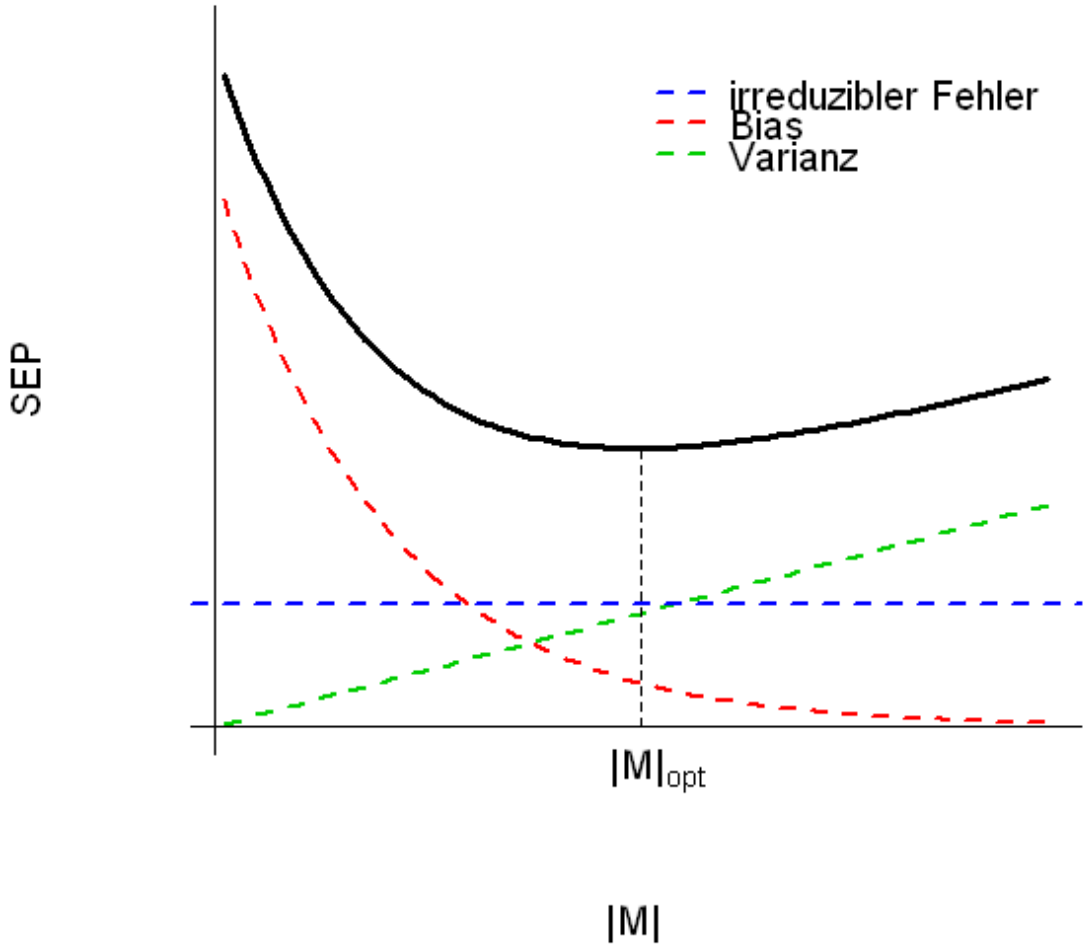
- **3.Term:**

$$\begin{aligned}\sum_{i=1}^{n}\mathbb{E}(\hat{Y}_i^{(M)} - \mu_i^{(M)})^2 &= \sum_{i=1}^{n} Var(\hat{Y}_i^{(M)}) \\ &= spur\left(Cov\left(\underline{\hat{Y}}^{(M)}\right)\right) \\ &= spur\left(Cov(\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\underline{Y})\right) \\ &= spur\left(\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\sigma^2\mathbb{I}_n\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\right) \\ &= \sigma^2 spur(\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T) \\ &\overset{spur(AB)=spur(BA)}{=} \sigma^2 spur(\mathbb{I}_{|M|}) \\ &= \sigma^2|M|\end{aligned}$$

  - ***Varianz-Term***
  - Varianz des Schätzers für den Erwartungswert der Zielgröße
  - Unsicherheit der Prognose, die sich aus der Notwendigkeit der Schätzung von $|M|$ unbekannten Parametern im Parametervektor $\underline{\beta}^{(M)}$ ergibt
  - hängt vom Kandidatenmodell M ab
  - steigt linear mit $|M|$

Bias-Variance- Tradeoff

Bias-Variance-Tradeoff



Methoden zur Schätzung des erwarteten Prognosefehlers

Grundsätzliches:

- Schätze $SEP^{(M)}$ für jedes der Kandidatenmodelle M

- Wähle dasjenige Modell mit kleinstem ***geschätzten*** erwarteten Prognosefehler

- Modellwahl ist ein statistisches Verfahren, d.h. das Ergebnis ist nicht das *wahre* Modell
  - unterschiedliche Methoden der Schätzung des $SEP^{(M)}$ können zu unterschiedlichen *besten* Kandidatenmodellen führen
  - ein neuer Datensatz kann selbst bei gleicher Methode der Schätzung zu einem anderen *besten* Modell führen.

- Ziel ist das Finden eines ***useful models***.

1) Schätzung von $SEP^{(M)}$ auf der Grundlage neuer Beobachtungen

- Ausgehend von Beobachtungen
  $$Y_1, \dots, Y_n$$
  und dazugehörigen Vektoren von potentiellen Einflussgrößen
  $$\underline{x}_i = (1, x_{i2}, \dots, x_{ik})^T \ , \ i = 1, \dots, n$$
  werden für jedes Kandidatenmodell $M \subseteq \{1, \dots, k\}$ die Parameterschätzer $\hat{\underline{\beta}}^{(M)}$ und die sich daraus ergebenden Prognosen $\hat{Y}_i^{(M)}$ bestimmt.

- Liegen zu den gleichen Einflussvektoren $\underline{x}_i = (1, x_{i2}, \dots, x_{ik})^T, i = 1, \dots, n$ neue unabhängige Beobachtungen
  $$Y_{n+i}, i = 1, \dots, n$$
  vor, so ist durch
  $$\widehat{SEP}^{(M)} = \sum_{i=1}^{n} (Y_{n+i} - \hat{Y}_i^{(M)})^2$$
  ein erwartungstreuer Schätzer für den Prognosefehler $SEP^{(M)}$ gegeben.

- Problem:
  - Datenerhebung ist zeit-und kostenaufwändig
  - Verdopplung des Aufwandes nur zum Zweck der Modellwahl meist nicht gerechtfertigt
  - Möglichkeit des *a posteriori*-Vergleichs unterschiedlicher bekannter Modellvorschläge an Hand neuer Datensätze (Beispiel Biomasse-Funktionen)

2) Zerlegung des Datensatzes in Trainings- und Testdaten

$$I = \{1, \dots, n\} = I_{train} \dot{\cup} I_{test}$$

- verwende den Trainingsdatensatz, um für alle Kandidatenmodelle M die Schätzwerte $\hat{\underline{\beta}}_{train}^{(M)}$ für den unbekannten Parametervektor $\underline{\beta}^{(M)}$ zu bestimmen

- verwende den Testdatensatz, um den erwarteten Prognosefehler zu schätzen:

$$\widehat{SEP}^{(M)} = \sum_{i \in I_{test}} \left(y_i - \hat{y}_{i,train}^{(M)} \right)^2$$
$$= \sum_{i \in I_{test}} \left(y_i - \underline{x}_i^T \, \hat{\underline{\beta}}_{train}^{(M)} \right)^2$$

- nur $|I_{test}|$ Summanden!
- übliche Aufteilung: 75-80% der Daten im Trainingsdatensatz
- Ergebnis der Modellwahl hängt von der konkreten Wahl des Testdatensatzes ab
  - zufällige Auswahl der Testdaten
  - stratifizierte Auswahl der Testdaten

3) Kreuzvalidierung

- mehrfache Zerlegung in Test-und Trainingsdatensatz, um den Einfluss der konkreten Auswahl zu reduzieren

- einfachste mögliche Umsetzung: mehrfache zufällige Aufteilung

- übliche Umsetzung: d-fache Kreuzvalidierung
  - Zerlegung des Datensatzes in d disjunkte Teildatensätze
$$I = I_1 \dot{\cup} I_2 \dot{\cup} \ \ldots \ \dot{\cup} I_d$$
  - jeder Teildatensatz wird einmal als Testdatensatz verwendet:
$$\widehat{SEP}^{(M)} = \sum_{j=1}^{d} \sum_{i \in I_j} \left(y_i - \hat{y}_{i,-I_j}^{(M)} \right)^2 = \sum_{j=1}^{d} \sum_{i \in I_j} \left(y_i - \underline{x}_i^T \hat{\underline{\beta}}_{-I_j}^{(M)} \right)^2$$
$$\hat{y}_{i,-I_j}^{(M)} \ - \ \text{Vorhersage für } \mathbb{E}Y_i \text{ basierend auf Teildatensatz } I \setminus I_j$$

- jede Beobachtung ist genau einmal im Testdatensatz enthalten

- jede Beobachtung ist $(d-1)$-mal im Trainingsdatensatz enthalten (stochastische Abhängigkeit der Vorhersagen)

- zufällige oder stratifizierte Zerlegung, ungefähr gleich große Teildatensätze

- Wahl von d:
  - $d = n$: leave-one-out cross validation (nicht zufällig!)

- $d = \min\{10, \sqrt{n}\}$: übliche Wahl

- Abhängigkeit von der Wahl der Zerlegung ist reduziert, aber nicht beseitigt

- Möglichkeit der mehrfach wiederholten Kreuzvalidierung mit unterschiedlichen Zerlegungen

4) Schätzung von $SEP^{(M)}$ auf der basierend auf der Residuenquadratsumme

- $RSS^{(M)}$ als natürlicher Kandidat für die Schätzung des Prognosefehlers:

$$RSS^{(M)} = \sum_{i=1}^{n} (y_i - \hat{y}_i^{(M)})^2$$

- misst die Abweichung zwischen Beobachtung und Prognose für den vorliegenden Datensatz

- Problem:
  - Beobachtungen $y_1, \dots, y_n$ fließen in die Schätzung $\hat{\underline{\beta}}^{(M)}$ des Parametervektors $\underline{\beta}^{(M)}$ ein
  - Prognosen passen zu den vorliegenden Daten besser als zu zukünftigen neuen Beobachtungen
  - potentielle Unterschätzung des Prognosefehlers
  - $RSS^{(M)}$ sinkt mit jeder hinzugefügten Einflussgröße

$$\begin{aligned}
\mathbb{E}RSS^{(M)} &= \mathbb{E}\sum_{i=1}^{n}(Y_i - \hat{Y}_i^{(M)})^2 \\
&= \sum_{i=1}^{n}\mathbb{E}(Y_i - \hat{Y}_i^{(M)})^2 = \sum_{i=1}^{n}\mathbb{E}(Y_i - \mu_i + \mu_i - \hat{Y}_i^{(M)})^2 \\
&= \sum_{i=1}^{n}\mathbb{E}(Y_i - \mu_i)^2 + \mathbb{E}(\hat{Y}_i^{(M)} - \mu_i)^2 + 2\mathbb{E}(Y_i - \mu_i)(\mu_i - \hat{Y}_i^{(M)}) \\
&= SEP^{(M)} + 2\mathbb{E}(Y_i - \mu_i)(\mu_i - \hat{Y}_i^{(M)})
\end{aligned}$$

- gemischter Term verschwindet nicht, da Y_i und $\hat{Y}_i^{(M)} = \hat{Y}_i^{(M)}(Y_1, \dots, Y_n)$ stochastisch abhängig

$$\begin{aligned}
\sum_{i=1}^{n}\mathbb{E}(Y_i - \mu_i)(\mu_i - \hat{Y}_i^{(M)}) &= \mathbb{E}(\underline{Y} - \underline{\mu})^T(\underline{\mu} - \hat{\underline{Y}}^{(M)}) \\
&= \mathbb{E}\underline{Y}^T\underline{\mu} - \mathbb{E}\underline{Y}^T\hat{\underline{Y}}^{(M)} - \underline{\mu}^T\underline{\mu} + \mathbb{E}\underline{\mu}^T\hat{\underline{Y}}^{(M)} \\
&= \underline{\mu}^T\underline{\mu} - \mathbb{E}\underline{Y}^T\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\underline{Y} - \underline{\mu}^T\underline{\mu} + \underline{\mu}^T\underline{\mu}^{(M)} \\
&= -\mathbb{E}\underline{Y}^T\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\underline{Y} + \underline{\mu}^T\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\underline{\mu}
\end{aligned}$$

Erinnerung: Erwartungswert quadratischer Formen

$$\mathbb{E}\underline{Y}^T \mathbb{A}\underline{Y} = \underline{\mu}^T \mathbb{A}\underline{\mu} + spur(\mathbb{A}\Sigma)$$

$$\begin{aligned}\sum_{i=1}^{n} \mathbb{E}(Y_i - \mu_i)(\mu_i - \hat{Y}_i^{(M)}) &= -spur(\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T Cov(\underline{Y})) \\ &= -\sigma^2 spur(\mathbb{X}_M(\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T) \\ &= -\sigma^2 spur((\mathbb{X}_M^T\mathbb{X}_M)^{-1}\mathbb{X}_M^T\mathbb{X}_M) \\ &= -\sigma^2 spur(\mathbb{I}_{|M|}) \\ &= -\sigma^2 \, |M|\end{aligned}$$

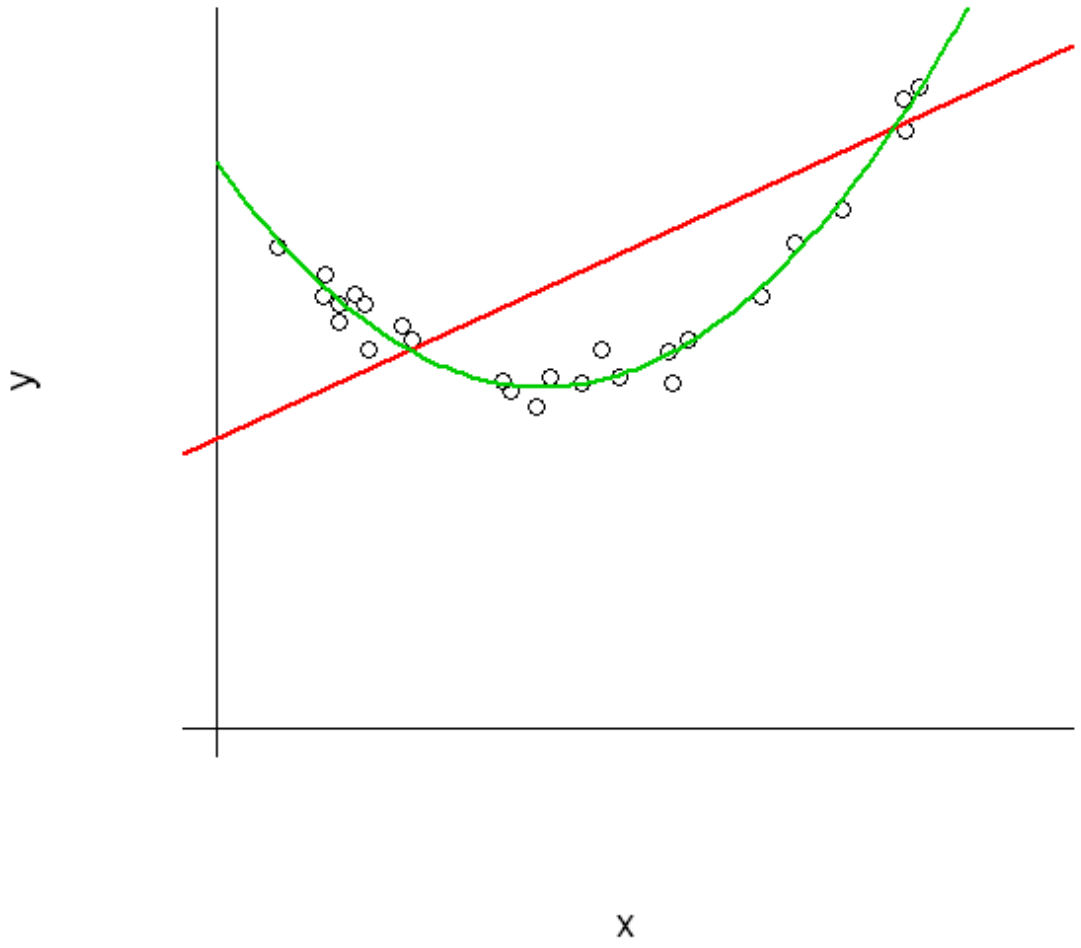
- Unterschätzung des Prognosefehlers $SEP^{(M)}$ durch $RSS^{(M)}$ kann quantifiziert werden:

$$SEP^{(M)} = \mathbb{E}RSS^{(M)} + 2\sigma^2 \, |M|$$

- natürlicher Schätzer:

$$\widehat{SEP}^{(M)} = RSS^{(M)} + 2\tilde{\sigma}^2 \, |M|$$

- zusätzliches Problem: Wenn unser Kandidatenmodell M falsch ist, dann kann zugehörige übliche Varianzschätzer $\tilde{\sigma}^2$ sehr schlecht sein


y
x

- Ausweg: verwende für ***alle*** Kandidatenmodelle M den Varianzschätzer aus dem maximalen Modell mit allen potentiellen Einflussgrößen

$$\widehat{SEP}^{(M)} = RSS^{(M)} + 2\tilde{\sigma}^2_{full}\ |M|$$

5) Mallow's C_p

- Mallow definierte einen sogenannten *Komplexitätsparameter* C_p (*Mallow's* C_p) als Hilfsmittel zur Modellwahl. Er ist definiert als:

$$C_p^{(M)} = \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i^{(M)})^2}{\tilde{\sigma}^2_{full}} - n + 2|M|$$

- Zusammenhang mit dem RSS-basierten Schätzer des Prognosefehlers $SEP^{(M)}$:

$$\begin{aligned} C_p^{(M)}\tilde{\sigma}^2_{full} &= \sum_{i=1}^{n}(Y_i - \hat{Y}_i^{(M)})^2 - n\tilde{\sigma}^2_{full} + 2|M|\tilde{\sigma}^2_{full} \\ &= \widehat{SEP}^{(M)} - n\tilde{\sigma}^2_{full} \end{aligned}$$

- Minimierung von $C_p^{(M)}$ ist äquivalent zur Minimierung von $SEP^{(M)}$, da $n\tilde{\sigma}^2_{full}$ unabhängig von M

- aus $C_p^{(M)}$ kann ein Schätzwert für $SEP^{(M)}$ berechnet werden

$$\widehat{SEP}^{(M)} = C_p^{(M)}\tilde{\sigma}^2_{full} + n\tilde{\sigma}^2_{full}$$

- **R**-Funktion zur Minimierung von Mallow's C_p im Paket `leaps`

Zusammenfassung zur Modellwahl bei klassischen linearen Modellen

- wir haben zwei grundsätzlich verschiedene Ansätze kennen gelernt
  - Modellwahl mit Hilfe statistischer Hypothesen-Tests
  - Modellwahl basierend auf geschätztem erwarteten Prognosefehler

Hypothesen-Tests

- sind geeignet:

- bei geplanten Experimenten mit klar definierten *a priori*-Hypothesen
- bei einer klar definierten *a priori*-Modellhierarchie

- Problematisch sind dabei:
  - ein willkürlich festgelegtes Signifikanzniveau α
  - Vergrößerung der Irrtumswahrscheinlichkeit 1.Art bei multiplem Testen
  - Vorwärts-Selektion ohne *a priori*-Modellhierarchie ist nicht sinnvoll

Modellwahl basierend auf geschätztem erwarteten Prognosefehler

- immer dann geeignet, wenn Prognose eigentliches Ziel der statistischen Modellbildung ist
- kein willkürlich gewähltes Signifikanzniveau, sondern objektives Auswahlkriterium
- Vorwärtsselektion und best subset selection sind prinzipiell möglich
- ABER: je größer die Menge der Kandidatenmodelle, desto größer die Wahrscheinlichkeit, dass ein Modell ausgewählt wird, das die Besonderheiten und nicht das Typische des konkreten vorliegenden Datensatzes betont
- der entscheidende Schritt bei dieser Vorgehensweise ist die Festlegung der Menge der Kandidatenmodelle
- empfohlene Vorgehensweise: kleine Zahl von Kandidatenmodellen basierend auf "Expertenwissen", dann direkter Vergleich an Hand des geschätzten erwarteten Prognosefehlers